



Universidad Nacional de Colombia

Departamento de Estadística – Facultad de Ciencias

Análisis de Regresión – 3006918

**MODELADO DE LOS INGRESOS MENSUALES DE EMPLEADOS EN
COLOMBIA**

Aplicación de un Modelo de Regresión Lineal Múltiple

Docente: Isabel Cristina Ramírez Guevara

Yuliany Cifuentes Rondon
Daniela Cataño Hernández
Samir Alejandro Centeno Torrado

Medellín, Colombia – Semestre 2026-1

Índice

1	Introducción	3
2	Contextualización del problema	3
3	Objetivo general	3
4	Descripción de las variables	3
4.1	Variable de respuesta	3
4.2	Variables explicativas	4
5	Modelo matemático propuesto	4
6	Relevancia del estudio	5
7	Hipótesis de investigación	5
7.1	Hipótesis 1: Significancia global del modelo	5
7.1.1	Hipótesis nula (H)	5
7.1.2	Hipótesis alternativa (H)	5
7.2	Hipótesis 2: Efecto del nivel educativo	6
7.2.1	Hipótesis nula (H)	6
7.2.2	Hipótesis alternativa (H)	6
7.3	Análisis Descriptivo	6
7.4	Conclusión General	10

1. Introducción

En el presente proyecto se desarrolla un modelo de regresión lineal múltiple para analizar los factores que influyen en el ingreso mensual de profesionales en Colombia. Se consideran variables relacionadas con características laborales, educativas y demográficas, con el propósito de identificar los determinantes más relevantes del salario y cuantificar su impacto sobre los ingresos.

2. Contextualización del problema

El ingreso laboral constituye uno de los principales indicadores del bienestar económico de las personas y de las condiciones del mercado laboral. En Colombia, los salarios pueden verse influenciados por diversos factores relacionados con la experiencia laboral, el nivel educativo, las características demográficas y el tipo de ocupación desempeñada por cada trabajador.

Comprender la relación entre estos factores y el ingreso laboral resulta fundamental para analizar las desigualdades salariales existentes en el mercado de trabajo y para identificar cuáles características tienen una mayor incidencia sobre los ingresos de los trabajadores. Además, este tipo de análisis aporta evidencia útil para el diseño de políticas públicas orientadas al fortalecimiento del empleo, la educación y la productividad laboral.

En este proyecto se propone desarrollar un modelo de regresión lineal múltiple con el propósito de explicar y predecir el ingreso laboral de los trabajadores en Colombia a partir de variables relacionadas con la intensidad de trabajo, la experiencia laboral, el nivel educativo alcanzado, las características demográficas y la posición ocupacional.

3. Objetivo general

Desarrollar un modelo de regresión lineal múltiple que permita explicar el ingreso laboral de los trabajadores en Colombia mediante variables relacionadas con las horas de trabajo, la experiencia laboral reciente, la posición ocupacional, la edad, el nivel educativo, el año de grado alcanzado y el sexo al nacer.

4. Descripción de las variables

4.1. Variable de respuesta

Y: Ingreso laboral mensual

Corresponde al ingreso mensual percibido por cada trabajador, expresado en pesos colombianos. Esta variable representa el fenómeno que se desea explicar mediante el modelo de regresión.

4.2. Variables explicativas

X : Horas de trabajo por semana

Número de horas que trabaja una persona durante una semana típica de trabajo. Se espera que una mayor cantidad de horas trabajadas esté asociada con mayores ingresos laborales.

X : Meses trabajados en los últimos 12 meses

Cantidad de meses durante los cuales la persona estuvo ocupada en el último año. Esta variable permite aproximar la estabilidad y continuidad laboral del individuo.

X : Posición ocupacional

Variable categórica que identifica la situación laboral del trabajador. Algunas categorías son:

- Empleado de empresa privada.
- Empleado del gobierno.
- Trabajador por cuenta propia.

Esta variable permite analizar si existen diferencias salariales asociadas al tipo de empleo desempeñado.

X : Edad

Edad del trabajador expresada en años cumplidos. La edad suele utilizarse como una aproximación a la experiencia acumulada y al ciclo laboral de las personas.

X : Nivel educativo más alto alcanzado

Máximo nivel de formación académica obtenido por el trabajador. Generalmente se espera que mayores niveles educativos se traduzcan en mayores oportunidades laborales y mejores ingresos.

X : Año de grado alcanzado

Año en el que la persona obtuvo su nivel educativo más alto. Esta variable puede reflejar la actualidad de la formación académica y la experiencia acumulada desde la graduación.

X : Sexo al nacer

Variable categórica que identifica el sexo registrado al nacer. Su inclusión permite analizar posibles diferencias en los ingresos laborales entre grupos poblacionales.

5. Modelo matemático propuesto

El modelo de regresión lineal múltiple puede expresarse como:

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 X_{3i} + \beta_4 X_{4i} + \beta_5 X_{5i} + \beta_6 X_{6i} + \beta_7 X_{7i} + \varepsilon_i$$

donde:

Símbolo	Descripción
Y_i	Ingreso laboral mensual del trabajador i .
X_1	Horas de trabajo por semana.
X_2	Meses trabajados en los últimos 12 meses.
X_3	Posición ocupacional.
X_4	Edad del trabajador.
X_5	Nivel educativo más alto alcanzado.
X_6	Año de grado alcanzado.
X_7	Sexo al nacer.
β_0	Intercepto del modelo.
$\beta_1, \dots, \beta_7$	Coefficientes asociados a las variables explicativas.
ε_i	Error aleatorio del modelo.

6. Relevancia del estudio

La identificación de los factores que determinan los ingresos laborales es un tema de gran interés en economía laboral y ciencias sociales. Los resultados obtenidos permitirán establecer qué características tienen una influencia significativa sobre los salarios y cuantificar la magnitud de dichos efectos. Asimismo, el análisis contribuirá a comprender las diferencias salariales asociadas al nivel educativo, la experiencia laboral, la posición ocupacional y otras características individuales.

7. Hipótesis de investigación

7.1. Hipótesis 1: Significancia global del modelo

7.1.1. Hipótesis nula (H)

Las variables explicativas incluidas en el modelo no tienen un efecto significativo sobre el ingreso laboral.

$$H_0 : \beta_1 = \beta_2 = \beta_3 = \beta_4 = \beta_5 = \beta_6 = \beta_7 = 0$$

7.1.2. Hipótesis alternativa (H)

Al menos una de las variables explicativas tiene un efecto significativo sobre el ingreso laboral.

$$H_1 : \exists, j \in 1, 2, 3, 4, 5, 6, 7 \text{ tal que } \beta_j \neq 0$$

7.2. Hipótesis 2: Efecto del nivel educativo

7.2.1. Hipótesis nula (H)

El nivel educativo más alto alcanzado no tiene un efecto significativo sobre el ingreso laboral.

$$H_0 : \beta_5 = 0$$

7.2.2. Hipótesis alternativa (H)


El nivel educativo más alto alcanzado tiene un efecto significativo sobre el ingreso laboral.

$$H_1 : \beta_5 \neq 0$$

7.3. Analisis Descriptivo

El ingreso laboral mensual presenta una distribucion altamente asimetrica, la media de 2.37M supera ampliamente la mediana de 1.5M, evidenciando la presencia de valores en la cola derecha de esta distribucion, el maximo de 34M aumenta la media hacia arriba. Esto justifica trabajar con el logaritmo de los ingresos como variable de respuesta del modelo


Ademas la edad promedio es de 41 años en un rango de 17-65 años, las horas semanales promedio de trabajo son 44, la mayoria trabajo los 12 meses completos del año (mediana y Q3 en 12)



El ingreso laboral mensual presenta una distribución marcadamente asimétrica hacia la derecha. La media muestral (~\$2.37 millones) supera ampliamente la mediana (~\$1.5 millones),

evidenciando observaciones extremas en la cola superior, con valores que alcanzan los \$34 millones mensuales. Esta asimetría viola el supuesto de normalidad requerido por el modelo de regresión lineal.

Al aplicar la transformación logarítmica, la distribución resultante se aproxima a una normal, estabilizando la varianza y reduciendo el efecto de los valores atípicos. Esta decisión es coherente con la teoría económica, que reconoce que los salarios siguen distribuciones log-normales. Por lo tanto, se utiliza **log(ingreso)** como variable de respuesta en el modelo.




Los boxplots revelan diferencias estructurales significativas entre las tres categorías:

Empleados del gobierno: presentan la mayor homogeneidad salarial, reflejada en una caja compacta con menor dispersión. Esto es consistente con los sistemas de escalas salariales estandarizadas del sector público.

Empleados de empresa particular: muestran una distribución moderada, pero con presencia de valores atípicos inferiores, indicando que un subgrupo del sector privado percibe ingresos considerablemente bajos respecto al resto.

Trabajadores por cuenta propia: exhiben la mayor variabilidad de los tres grupos, con bigotes amplios y alta dispersión intercuartílica, reflejando la coexistencia de profesionales independientes con ingresos elevados y trabajadores informales con ingresos muy reducidos.


Conclusión: la posición ocupacional genera diferencias sistemáticas en los niveles salariales y es una variable explicativa relevante para el modelo.



Los resultados evidencian una brecha salarial entre hombres y mujeres. La mediana del logaritmo del ingreso es ligeramente superior en los hombres, equivalente a una diferencia aproximada de **\$1.8 millones** en la escala original.

La distribución del ingreso femenino presenta mayor variabilidad hacia la parte inferior, con tres valores atípicos por debajo del bigote inferior, mientras que la distribución masculina no registra atípicos. Los bigotes del grupo femenino son más amplios hacia abajo, indicando mayor concentración de ingresos bajos en dicho grupo.

Conclusión: el sexo tiene potencial explicativo en el modelo, siendo coherente con la literatura sobre desigualdad salarial de género en el mercado laboral colombiano.



Los gráficos de dispersión muestran el siguiente comportamiento:

Nivel educativo: relación positiva más clara y consistente. A mayor nivel educativo, mayor es el ingreso observado. Es la variable continua de mayor poder explicativo individual.

Horas de trabajo por semana: tendencia positiva moderada. Mayor número de horas se asocia con ingresos más altos, lo cual es esperable económicamente.

Edad, grado aprobado y meses trabajados: no muestran patrones lineales evidentes con el log(ingreso), sugiriendo una contribución explicativa limitada de forma individual.

	log_ingreso	horas	edad	educacion	grado
log_ingreso	1.00000000	0.39846636	0.01058834	0.67508138	0.48540503
horas	0.39846636	1.00000000	-0.05318382	0.09879153	0.15914795
edad	0.01058834	-0.05318382	1.00000000	-0.20429904	-0.08570578
educacion	0.67508138	0.09879153	-0.20429904	1.00000000	0.60853218
grado	0.48540503	0.15914795	-0.08570578	0.60853218	1.00000000
meses_trab	0.27540977	0.11291573	0.17626308	0.16626668	0.20000341
meses_trab					
log_ingreso	0.2754098				
horas	0.1129157				
edad	0.1762631				
educacion	0.1662667				
grado	0.2000034				
meses_trab	1.0000000				

La matriz de correlaciones confirma los hallazgos gráficos:

Educación registra la correlación más alta con el log(ingreso), consolidándose como el principal predictor cuantitativo del modelo.

Se detecta una **correlación de ~0.60 entre educación y grado**, lo que constituye una alerta de multicolinealidad entre estos dos predictores. Esta situación deberá evaluarse con el **Factor de Inflación de la Varianza (VIF)** en la fase de ajuste del modelo.

Empleado_particular	Empleado_gobierno	Cuenta_propia
34	32	34

Hombre	Mujer
47	53

	Hombre	Mujer
Empleado_particular	7	27
Empleado_gobierno	19	13
Cuenta_propia	21	13

La tabla de frecuencias confirma que la muestra está balanceada entre las tres posiciones ocupacionales (~33-34 individuos por grupo), resultado del muestreo estratificado aplicado. La distribución cruzada con sexo muestra que ninguna categoría ocupacional concentra de forma excesiva a un solo grupo, lo que garantiza comparaciones válidas entre grupos y condiciones adecuadas para el ajuste del modelo de regresión lineal múltiple.

7.4. Conclusión General

El nivel educativo es el principal determinante del ingreso laboral en Colombia, seguido de la posición ocupacional y el sexo del trabajador. Las horas semanales muestran una contribución positiva moderada, mientras que la edad, el año de grado y los meses trabajados presentan menor relevancia explicativa en términos descriptivos.

La transformación logarítmica del ingreso se justifica plenamente ante la asimetría observada. La posible multicolinealidad entre educación y grado debe tratarse en etapas posteriores, ya sea eliminando una de las variables, combinándolas, o mediante técnicas de regularización.

En conjunto, los resultados son coherentes con la **teoría del capital humano** y con la evidencia empírica sobre el mercado laboral colombiano, proveyendo una base sólida para la estimación del modelo de regresión lineal múltiple.