



Universidad Nacional de Colombia
Departamento de Estadística – Facultad de Ciencias

Análisis de Regresión – 3006918

**MODELADO DE LOS INGRESOS MENSUALES DE EMPLEADOS EN
COLOMBIA**

Aplicación de un Modelo de Regresión Lineal Múltiple

Docente: Isabel Cristina Ramírez Guevara

Yuliany Cifuentes Rondon
Daniela Cataño Hernández
Samir Alejandro Centeno Torrado

Medellín, Colombia – Semestre 2026-1

Índice

1	Enunciado del proyecto	3
2	Introducción	3
3	Contextualización del problema	3
4	Objetivo general	4
5	Relevancia del estudio	4
6	Descripción de las variables	4
6.1	Variable de respuesta	4
6.2	Variables explicativas	5
7	Modelo matemático propuesto	6
8	Hipótesis de investigación	6
8.1	Hipótesis 1: Significancia global del modelo	6
8.1.1	Hipótesis nula (H)	6
8.1.2	Hipótesis alternativa (H)	6
8.2	Hipótesis 2: Efecto del nivel educativo	7
8.2.1	Hipótesis nula (H)	7
8.2.2	Hipótesis alternativa (H)	7
8.3	Análisis Descriptivo	7
8.4	Conclusión General	11

1. Enunciado del proyecto

El proyecto consiste en buscar una base de datos con datos colombianos que contenga una variable de respuesta continua (), al menos cinco covariables continuas () y una variable categórica () con al menos tres categorías. Los análisis se realizan con máximo 100 registros. El proyecto tiene tres entregas y una exposición final.

1. Contextualizar el fenómeno a modelar: explicar el significado de la variable de respuesta y las covariables, la relevancia del estudio y su objetivo. Establecer dos hipótesis que se desean probar con el modelo.
2. Realizar un análisis descriptivo exhaustivo y pertinente para el tipo de modelo que se va a aplicar.

2. Introducción

En el presente proyecto se desarrolla un modelo de regresión lineal múltiple para analizar los factores que influyen en el ingreso mensual de profesionales en Colombia. Se consideran variables relacionadas con características laborales, educativas y demográficas, con el propósito de identificar los determinantes más relevantes del salario y cuantificar su impacto sobre los ingresos.

3. Contextualización del problema

El ingreso laboral es una de las variables centrales para el estudio del bienestar económico y del funcionamiento del mercado de trabajo. Desde la teoría del capital humano, propuesta originalmente por Mincer, se plantea que el salario de un individuo puede explicarse en buena medida por su nivel de escolaridad y por su experiencia laboral entendida esta última como una proxy del entrenamiento adquirido en el puesto de trabajo [1]. Este marco teórico dio origen a la conocida *ecuación de Mincer*, que modela el logaritmo del ingreso como función lineal de la educación y de la experiencia (y su forma cuadrática) y que constituye hasta hoy el punto de partida estándar para el análisis empírico de los determinantes salariales.

En el caso colombiano, esta relación ha sido documentada de manera consistente. Núñez y Sánchez [2] utilizando información de encuestas de hogares del DANE encuentran que la escolaridad ha sido el factor con mayor poder explicativo sobre los diferenciales de ingreso laboral en el país, y que su efecto se ha mantenido estable a lo largo de distintos periodos. En la misma línea Guataquí et al. [3], con datos de la Gran Encuesta Integrada de Hogares (GEIH), muestran que además de la educación, variables como la posición ocupacional y la experiencia potencial explican una parte relevante de la heterogeneidad salarial observada, y advierten sobre la importancia de separar estos efectos entre asalariados y trabajadores por cuenta propia, dado que ambos grupos responden a estructuras de determinación de ingresos distintas.

Estudios más recientes del banco de la república [4] confirman que estos patrones persisten e incluso se intensifican en contextos de choques económicos: al modelar los determinantes del ingreso laboral para el periodo 2010-2019, encuentran que la brecha salarial asociada al sexo

del trabajador y a la posición ocupacional continua siendo estadísticamente significativa una vez controlado por nivel educativo. A nivel de subgrupos poblacionales específicos, Panorama Económico [5] aplica una ecuación minceriana a profesionales en economía y encuentra que un año adicional de formación escolar incrementa significativamente la probabilidad de percibir ingresos más altos, evidenciando que el efecto de la educación sobre el salario no es homogéneo entre grupos ocupacionales, sino que varía según el perfil profesional analizado.

En conjunto, esta literatura sugiere que un modelo del ingreso laboral en Colombia debe incorporar, como mínimo, variables asociadas a la educación, la experiencia o antigüedad laboral, la posición ocupacional y el sexo del trabajador, dado que son los determinantes que de manera recurrente resultan significativos en los estudios previos. El presente proyecto retoma este marco para proponer un modelo de regresión lineal múltiple sobre una muestra de trabajadores colombianos incluyendo adicionalmente variables como la intensidad de trabajo (horas semanales) y el año de graduación, con el fin de evaluar si estos factores adicionales aportan poder explicativo más allá de lo ya documentado en la literatura.

4. Objetivo general

Desarrollar un modelo de regresión lineal múltiple que permita explicar el logaritmo del ingreso laboral mensual de los trabajadores en Colombia a partir de variables asociadas a la teoría del capital humano y a la literatura empírica sobre determinantes salariales en el país, específicamente las horas de trabajo semanales, la experiencia laboral reciente, la posición ocupacional, la edad, el nivel educativo, el año de grado alcanzado y el sexo del trabajador.

5. Relevancia del estudio

La identificación de los factores que determinan los ingresos laborales es un tema central en la economía laboral y ha sido ampliamente estudiado en Colombia desde la perspectiva del capital humano [1, 2]. Sin embargo, buena parte de esta literatura se ha concentrado en variables de escolaridad y experiencia, dejando en un segundo plano el análisis conjunto con variables como la intensidad y continuidad laboral (horas trabajadas y meses de ocupación en el último año). Este proyecto busca aportar evidencia adicional sobre el peso relativo de estos factores frente a los determinantes tradicionales, replicando además la evidencia existente sobre la brecha salarial asociada al sexo y a la posición ocupacional documentada por el banco de la república [4]. Los resultados permitirán establecer que características tienen una influencia significativa sobre los salarios en la muestra analizada y contrastar estos hallazgos con lo reportado en la literatura previa.

6. Descripción de las variables

6.1. Variable de respuesta

Y: Ingreso laboral mensual

Corresponde al ingreso mensual percibido por cada trabajador, expresado en pesos colombianos. Esta variable representa el fenómeno que se desea explicar mediante el modelo de regresión.

6.2. Variables explicativas

X : Horas de trabajo por semana

Número de horas que trabaja una persona durante una semana típica de trabajo. Se espera que una mayor cantidad de horas trabajadas esté asociada con mayores ingresos laborales.

X : Meses trabajados en los últimos 12 meses

Cantidad de meses durante los cuales la persona estuvo ocupada en el último año. Esta variable permite aproximar la estabilidad y continuidad laboral del individuo.

X : Posición ocupacional

Variable categórica que identifica la situación laboral del trabajador. Algunas categorías son:

- Empleado de empresa privada.
- Empleado del gobierno.
- Trabajador por cuenta propia.

Esta variable permite analizar si existen diferencias salariales asociadas al tipo de empleo desempeñado.

X : Edad

Edad del trabajador expresada en años cumplidos. La edad suele utilizarse como una aproximación a la experiencia acumulada y al ciclo laboral de las personas.

X : Nivel educativo más alto alcanzado

Máximo nivel de formación académica obtenido por el trabajador. Generalmente se espera que mayores niveles educativos se traduzcan en mayores oportunidades laborales y mejores ingresos.

X : Año de grado alcanzado

Año en el que la persona obtuvo su nivel educativo más alto. Esta variable puede reflejar la actualidad de la formación académica y la experiencia acumulada desde la graduación.

X : Sexo al nacer

Variable categórica que identifica el sexo registrado al nacer. Su inclusión permite analizar posibles diferencias en los ingresos laborales entre grupos poblacionales.

7. Modelo matemático propuesto

El modelo de regresión lineal múltiple puede expresarse como:

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 X_{3i} + \beta_4 X_{4i} + \beta_5 X_{5i} + \beta_6 X_{6i} + \beta_7 X_{7i} + \varepsilon_i$$

donde:

Símbolo	Descripción
Y_i	Ingreso laboral mensual del trabajador i .
X_1	Horas de trabajo por semana.
X_2	Meses trabajados en los últimos 12 meses.
X_3	Posición ocupacional.
X_4	Edad del trabajador.
X_5	Nivel educativo más alto alcanzado.
X_6	Año de grado alcanzado.
X_7	Sexo al nacer.
β_0	Intercepto del modelo.
$\beta_1, \dots, \beta_7$	Coefficientes asociados a las variables explicativas.
ε_i	Error aleatorio del modelo.

8. Hipótesis de investigación

8.1. Hipótesis 1: Significancia global del modelo

8.1.1. Hipótesis nula (H)

Las variables explicativas incluidas en el modelo no tienen un efecto significativo sobre el ingreso laboral.

$$H_0 : \beta_1 = \beta_2 = \beta_3 = \beta_4 = \beta_5 = \beta_6 = \beta_7 = 0$$

8.1.2. Hipótesis alternativa (H)

Al menos una de las variables explicativas tiene un efecto significativo sobre el ingreso laboral.

$$H_1 : \exists, j \in 1, 2, 3, 4, 5, 6, 7 \text{ tal que } \beta_j \neq 0$$

8.2. Hipótesis 2: Efecto del nivel educativo

8.2.1. Hipótesis nula (H_0)

El nivel educativo más alto alcanzado no tiene un efecto significativo sobre el ingreso laboral.

$$H_0 : \beta_5 = 0$$

8.2.2. Hipótesis alternativa (H_1)

El nivel educativo más alto alcanzado tiene un efecto significativo sobre el ingreso laboral.

$$H_1 : \beta_5 \neq 0$$

8.3. Analisis Descriptivo

El ingreso laboral mensual presenta una distribucion altamente asimetrica, la media de 2.37M supera ampliamente la mediana de 1.5M, evidenciando la presencia de valores en la cola derecha de esta distribucion, el maximo de 34M aumenta la media hacia arriba. Esto justifica trabajar con el logaritmo de los ingresos como variable de respuesta del modelo

Ademas la edad promedio es de 41 años en un rango de 17-65 años, las horas semanales promedio de trabajo son 44, la mayoria trabajo los 12 meses completos del año (mediana y Q3 en 12)




Figura 1: Distribución del ingreso laboral mensual y su transformación logarítmica.

Como se observa en la Figura 1, el ingreso laboral mensual presenta una distribución marcadamente asimétrica hacia la derecha. La media muestral (~\$2.37 millones) supera ampliamente la mediana (~\$1.5 millones), evidenciando observaciones extremas en la cola superior, con valores que alcanzan los \$34 millones mensuales. Esta asimetría viola el supuesto de normalidad requerido por el modelo de regresión lineal.

Al aplicar la transformación logarítmica, la distribución resultante se aproxima a una normal, estabilizando la varianza y reduciendo el efecto de los valores atípicos. Esta decisión es coherente con la teoría económica, que reconoce que los salarios siguen distribuciones log-normales. Por lo tanto, se utiliza $\log(\text{ingreso})$ como variable de respuesta en el modelo.




Figura 2: Distribución del logaritmo del ingreso según posición ocupacional.

La Figura 2 revela diferencias estructurales entre las tres categorías:

Empleados del gobierno: presentan la mayor homogeneidad salarial, reflejada en una caja compacta con menor dispersión. Esto es consistente con los sistemas de escalas salariales estandarizadas del sector público.

Empleados de empresa particular: muestran una distribución moderada, pero con presencia de valores atípicos inferiores, indicando que un subgrupo del sector privado percibe ingresos considerablemente bajos respecto al resto.

Trabajadores por cuenta propia: exhiben la mayor variabilidad de los tres grupos, con bigotes amplios y alta dispersión intercuartílica, reflejando la coexistencia de profesionales independientes con ingresos elevados y trabajadores informales con ingresos muy reducidos.

Conclusión: la posición ocupacional genera diferencias sistemáticas en los niveles salariales y es una variable explicativa relevante para el modelo.




Figura 3: Distribución del logaritmo del ingreso por sexo.

Los resultados en la Figura 3 evidencian una brecha salarial entre hombres y mujeres. La mediana del logaritmo del ingreso es ligeramente superior en los hombres, equivalente a una diferencia aproximada de **\$1.8 millones** en la escala original.

La distribución del ingreso femenino presenta mayor variabilidad hacia la parte inferior, con tres valores atípicos por debajo del bigote inferior, mientras que la distribución masculina no registra atípicos. Los bigotes del grupo femenino son más amplios hacia abajo, indicando mayor concentración de ingresos bajos en dicho grupo.

Conclusión: el sexo tiene potencial explicativo en el modelo, siendo coherente con la literatura sobre desigualdad salarial de género en el mercado laboral colombiano.




Figura 4: Relación entre $\log(\text{ingreso})$ y las covariables continuas: edad, horas semanales, nivel educativo, grado aprobado y meses trabajados.

Los gráficos de dispersión observados en la Figura 4 muestran el siguiente comportamiento:

Nivel educativo: relación positiva más clara y consistente. A mayor nivel educativo, mayor es el ingreso observado. Es la variable continua de mayor poder explicativo individual.

Horas de trabajo por semana: tendencia positiva moderada. Mayor número de horas se asocia con ingresos más altos, lo cual es esperable económicamente.

Edad, grado aprobado y meses trabajados: no muestran patrones lineales evidentes con el $\log(\text{ingreso})$, sugiriendo una contribución explicativa limitada de forma individual.

Tabla 1: Matriz de correlaciones entre el logaritmo del ingreso y las covariables continuas.

Variable	log_ingreso	horas	edad	educacion	grado	meses_trab
log_ingreso	1.000	0.398	0.011	0.675	0.485	0.275
horas	0.398	1.000	-0.053	0.099	0.159	0.113
edad	0.011	-0.053	1.000	-0.204	-0.086	0.176
educacion	0.675	0.099	-0.204	1.000	0.609	0.166
grado	0.485	0.159	-0.086	0.609	1.000	0.200
meses_trab	0.275	0.113	0.176	0.166	0.200	1.000

La Tabla 1 confirma los hallazgos gráficos:

Educación registra la correlación más alta con el $\log(\text{ingreso})$, consolidándose como el principal predictor cuantitativo del modelo.

Se detecta una **correlación de ~0.60 entre educación y grado**, lo que constituye una alerta de multicolinealidad entre estos dos predictores. Esta situación deberá evaluarse con el **Factor de Inflación de la Varianza (VIF)** en la fase de ajuste del modelo.

Tabla 2: Distribución de la muestra por posición ocupacional.

Posición ocupacional	Frecuencia
Empleado_particular	34
Empleado_gobierno	32
Cuenta_propia	34

Tabla 3: Distribución cruzada de posición ocupacional y sexo.

	Hombre	Mujer
Empleado_particular	7	27
Empleado_gobierno	19	13
Cuenta_propia	21	13

La Tabla 2 muestra que la muestra está balanceada entre las tres posiciones ocupacionales (~33-34 individuos por grupo). La Tabla 3 confirma que ninguna categoría ocupacional concentra de forma excesiva a un solo grupo, lo que garantiza comparaciones válidas entre grupos y condiciones adecuadas para el ajuste del modelo de regresión lineal múltiple.

8.4. Conclusión General

El nivel educativo es el principal determinante del ingreso laboral en Colombia, seguido de la posición ocupacional y el sexo del trabajador. Las horas semanales muestran una contribución positiva moderada, mientras que la edad, el año de grado y los meses trabajados presentan menor relevancia explicativa en términos descriptivos.

La transformación logarítmica del ingreso se justifica plenamente ante la asimetría observada. La posible multicolinealidad entre educación y grado debe tratarse en etapas posteriores, ya sea eliminando una de las variables, combinándolas, o mediante técnicas de regularización.

En conjunto, los resultados son coherentes con la **teoría del capital humano** y con la evidencia empírica sobre el mercado laboral colombiano, proveyendo una base sólida para la estimación del modelo de regresión lineal múltiple.

Referencias

- [1] Mincer, J. (1974). *Schooling, Experience, and Earnings*. Columbia University Press.
- [2] Núñez, J. & Sánchez, F. (1998). Educación y salarios relativos en Colombia, 1976-1995: Determinantes, evolución e implicaciones para la distribución del ingreso. *Archivos de Macroeconomía*, No. 74. Departamento Nacional de Planeación, Bogotá.

- [3] Guataquí, J. C., García, A. & Rodríguez, M. Estimaciones de los determinantes de los ingresos laborales en Colombia. Banco de la República.
- [4] Banco de la República (2021). Desigualdades del ingreso en Colombia: ¿cuáles son sus determinantes y cómo se han afectado por la pandemia del Covid-19? *Ensayos sobre Política Económica*, No. 101.
- [5] Determinantes de los ingresos laborales de los economistas en Colombia: un análisis de modelación microeconómica (2019). *Panorama Económico*, Universidad de Cartagena.