



Universidad Nacional de Colombia

Departamento de Estadística – Facultad de Ciencias

Análisis de Regresión – 3006918

**MODELADO DE LOS INGRESOS MENSUALES DE EMPLEADOS EN
COLOMBIA**

Aplicación de un Modelo de Regresión Lineal Múltiple

Docente: Isabel Cristina Ramírez Guevara

Yuliany Cifuentes Rondon
Daniela Cataño Hernández
Samir Alejandro Centeno Torrado

Medellín, Colombia – Semestre 2026-1

Índice

1	Enunciado del proyecto	3
2	Introducción	3
3	Contextualización del problema	3
4	Objetivo general	4
5	Relevancia del estudio	4
5.1	Variables seleccionadas	4
5.1.1	Descripción detallada de las variables	5
6	Modelo matemático propuesto	6
6.1	Hipótesis	6
7	Análisis descriptivo	7
7.1	Información sobre la base de datos	7
7.2	Selección de la muestra	9
7.3	Base consolidada	10
7.4	Variable respuesta: logaritmo del ingreso laboral mensual	10
7.5	Descripción de las covariables continuas	11
7.6	Descripción de las variables categóricas	15
7.6.1	Posición ocupacional	15
7.6.2	Rama de actividad económica	15
8	Modelo matemático propuesto	17
9	Conclusiones	18

1. Enunciado del proyecto

El proyecto consiste en buscar una base de datos con datos colombianos que contenga una variable de respuesta continua (), al menos cinco covariables continuas () y una variable categórica () con al menos tres categorías. Los análisis se realizan con máximo 100 registros. El proyecto tiene tres entregas y una exposición final.

1. Contextualizar el fenómeno a modelar: explicar el significado de la variable de respuesta y las covariables, la relevancia del estudio y su objetivo. Establecer dos hipótesis que se desean probar con el modelo.
2. Realizar un análisis descriptivo exhaustivo y pertinente para el tipo de modelo que se va a aplicar.

2. Introducción

En el presente proyecto se desarrolla un modelo de regresión lineal múltiple para analizar los factores que influyen en el ingreso mensual de profesionales en Colombia. Se consideran variables relacionadas con características laborales, educativas y demográficas, con el propósito de identificar los determinantes más relevantes del salario y cuantificar su impacto sobre los ingresos.

3. Contextualización del problema

El ingreso laboral es una de las variables centrales para el estudio del bienestar económico y del funcionamiento del mercado de trabajo. Desde la teoría del capital humano, propuesta originalmente por Mincer, se plantea que el salario de un individuo puede explicarse en buena medida por su nivel de escolaridad y por su experiencia laboral entendida esta última como una proxy del entrenamiento adquirido en el puesto de trabajo [1]. Este marco teórico dio origen a la conocida *ecuación de Mincer*, que modela el logaritmo del ingreso como función lineal de la educación y de la experiencia (y su forma cuadrática) y que constituye hasta hoy el punto de partida estándar para el análisis empírico de los determinantes salariales.

En el caso colombiano, esta relación ha sido documentada de manera consistente. Núñez y Sánchez [2] utilizando información de encuestas de hogares del DANE encuentran que la escolaridad ha sido el factor con mayor poder explicativo sobre los diferenciales de ingreso laboral en el país, y que su efecto se ha mantenido estable a lo largo de distintos periodos. En la misma línea Guataquí et al. [3], con datos de la Gran Encuesta Integrada de Hogares (GEIH), muestran que además de la educación, variables como la posición ocupacional y la experiencia potencial explican una parte relevante de la heterogeneidad salarial observada, y advierten sobre la importancia de separar estos efectos entre asalariados y trabajadores por cuenta propia, dado que ambos grupos responden a estructuras de determinación de ingresos distintas.

Estudios más recientes del banco de la república [4] confirman que estos patrones persisten e incluso se intensifican en contextos de choques económicos: al modelar los determinantes del ingreso laboral para el periodo 2010-2019, encuentran que la brecha salarial asociada al sexo

del trabajador y a la posición ocupacional continua siendo estadísticamente significativa una vez controlado por nivel educativo. A nivel de subgrupos poblacionales específicos, Panorama Económico [5] aplica una ecuación minceriana a profesionales en economía y encuentra que un año adicional de formación escolar incrementa significativamente la probabilidad de percibir ingresos más altos, evidenciando que el efecto de la educación sobre el salario no es homogéneo entre grupos ocupacionales, sino que varía según el perfil profesional analizado.

En conjunto, esta literatura sugiere que un modelo del ingreso laboral en Colombia debe incorporar, como mínimo, variables asociadas a la educación, la experiencia o antigüedad laboral, la posición ocupacional y el sexo del trabajador, dado que son los determinantes que de manera recurrente resultan significativos en los estudios previos. El presente proyecto retoma este marco para proponer un modelo de regresión lineal múltiple sobre una muestra de trabajadores colombianos incluyendo adicionalmente variables como la intensidad de trabajo (horas semanales) y el año de graduación, con el fin de evaluar si estos factores adicionales aportan poder explicativo más allá de lo ya documentado en la literatura.

4. Objetivo general

Desarrollar un modelo de regresión lineal múltiple que permita explicar el logaritmo del ingreso laboral mensual de los trabajadores en Colombia a partir de variables asociadas a la teoría del capital humano y a la literatura empírica sobre determinantes salariales en el país, específicamente las horas de trabajo semanales, la experiencia laboral reciente, la posición ocupacional, la edad, el nivel educativo, el año de grado alcanzado y el sexo del trabajador.

5. Relevancia del estudio

La identificación de los factores que determinan los ingresos laborales es un tema central en la economía laboral y ha sido ampliamente estudiado en Colombia desde la perspectiva del capital humano [1, 2]. Sin embargo, buena parte de esta literatura se ha concentrado en variables de escolaridad y experiencia, dejando en un segundo plano el análisis conjunto con variables como la intensidad y continuidad laboral (horas trabajadas y meses de ocupación en el último año). Este proyecto busca aportar evidencia adicional sobre el peso relativo de estos factores frente a los determinantes tradicionales, replicando además la evidencia existente sobre la brecha salarial asociada al sexo y a la posición ocupacional documentada por el banco de la república [4]. Los resultados permitirán establecer que características tienen una influencia significativa sobre los salarios en la muestra analizada y contrastar estos hallazgos con lo reportado en la literatura previa.

5.1. Variables seleccionadas

Tabla 1: Variables seleccionadas, rol en el modelo y significado en el estudio.

Nombre	Código	Rol	Tipo	Significado
Logaritmo del ingreso laboral mensual	INGLABO (transformada)	Y	Continua	Ingreso laboral mensual transformado a escala logarítmica para reducir la asimetría de la distribución.
Horas trabajadas por semana	P6800	X1	Continua	Intensidad del trabajo desarrollado durante la semana de referencia.
Años de escolaridad	P3042 / P3042S1 (derivada)	X2	Continua	Años de educación formal aprobados; mide la acumulación de capital humano.
Experiencia potencial	P6040, P3042, P3042S1 (derivada)	X3	Continua	Edad - escolaridad - 6; aproxima los años potenciales de experiencia laboral.
Experiencia potencial al cuadrado	Derivada de X3	X4	Continua	Captura el efecto no lineal (rendimientos decrecientes) de la experiencia sobre el ingreso.
Antigüedad en el empleo actual	P6426	X5	Continua	Meses en el empleo u ocupación actual; aproxima estabilidad y experiencia específica.
Rama de actividad económica	RAMA2D_R4	X6 (Z)	Categórica	Sector económico (CIU, 2 dígitos) en el que se desempeña el trabajador.

5.1.1. Descripción detallada de las variables

Y: Logaritmo del ingreso laboral mensual. La variable de respuesta corresponde al ingreso laboral mensual percibido por las personas ocupadas incluidas en la GEIH, expresado en pesos colombianos. Dado que en economía laboral es ampliamente reconocido que la distribución de los ingresos presenta una marcada asimetría positiva, la variable dependiente se transforma mediante el logaritmo natural, lo que reduce la asimetría, disminuye la influencia de valores extremos y permite interpretar los coeficientes del modelo como variaciones porcentuales aproximadas del ingreso (especificación clásica de Mincer, 1974).

X1: Horas trabajadas por semana. Número de horas que la persona trabajó habitualmente durante la semana de referencia en su ocupación principal. Se espera una relación positiva con el ingreso.

X2: Años de escolaridad. Construida a partir del nivel educativo alcanzado (P3042) y el último grado aprobado dentro de ese nivel (P3042S1), siguiendo la convención estándar de conversión a años acumulados de educación usada en estudios de mercado laboral con la GEIH.

X3: Experiencia potencial. Se calcula como Edad – Escolaridad – 6, asumiendo que las personas ingresan al sistema educativo aproximadamente a los seis años y comienzan su vida laboral al finalizar su formación.

X4: Experiencia potencial al cuadrado. Incorpora la relación cóncava entre experiencia e ingreso: los ingresos aumentan con la experiencia, pero a una tasa decreciente.

X5: Antigüedad en el empleo actual. Meses que el trabajador lleva en su empleo u ocupación actual; aproxima estabilidad laboral y experiencia específica en la organización.

X6 (Z2): Rama de actividad económica. Sector económico en el que se desempeña el trabajador, agrupado según la Clasificación Industrial Internacional Uniforme (CIU) a 2 dígitos.

6. Modelo matemático propuesto

Con fundamento en la teoría del capital humano y en la especificación clásica de la ecuación de ingresos de Mincer, se propone estimar un modelo de regresión lineal múltiple en el que el logaritmo natural del ingreso laboral mensual constituye la variable dependiente:

$$\ln(Y_i) = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 X_{3i} + \beta_4 X_{4i} + \beta_5 X_{5i} + \beta_6 X_{6i} + \beta_7 X_{7i} + \varepsilon_i$$

donde X_1 : horas trabajadas por semana; X_2 : años de escolaridad; X_3 : experiencia potencial; X_4 : experiencia potencial al cuadrado; X_5 : posición ocupacional (dummy); X_6 : antigüedad en el empleo actual; X_7 : rama de actividad económica (dummy); β_0 : intercepto; ε_i : error aleatorio.

Antes de estimar el modelo definitivo se verificará el cumplimiento de los supuestos de la regresión lineal múltiple, evaluando la existencia de multicolinealidad mediante el Factor de Inflación de la Varianza (VIF), la homocedasticidad de los residuos, la normalidad de los errores y la posible presencia de observaciones influyentes.

6.1. Hipótesis

Las siguientes hipótesis se desprenden directamente de la contextualización presentada en la Introducción y la Relevancia (teoría del capital humano de Mincer, 1974, y la heterogeneidad del mercado laboral colombiano). Cada una se plantea de forma que pueda traducirse, en la etapa de modelación, en el signo y la significancia esperados de parámetros específicos del modelo $\ln(Y_i) = \beta_0 + \beta_1 X_{1i} + \dots + \beta_7 X_{7i} + \varepsilon_i$.

Hipótesis 1: la escolaridad y la experiencia potencial explican una parte sustancial de la variabilidad del ingreso laboral. De acuerdo con la teoría del capital humano, se espera que los trabajadores con mayor escolaridad y mayor experiencia potencial —hasta el punto en que los rendimientos empiezan a decrecer— perciban ingresos más altos. En términos del modelo, esta hipótesis se traduce en $\beta_2 > 0$ (escolaridad), $\beta_3 > 0$ (experiencia) y $\beta_4 < 0$ (experiencia al cuadrado), reflejando el perfil cóncavo típico de la ecuación de Mincer; se espera además que ambos coeficientes sean estadísticamente significativos.

Hipótesis 2: la posición ocupacional y la rama de actividad económica generan diferencias sistemáticas en el ingreso, incluso después de considerar la escolaridad y la experiencia. Dada la heterogeneidad e informalidad del mercado laboral colombiano descrita en la Relevancia, se espera que existan brechas de ingreso entre categorías ocupacionales y sectoriales que la educación y la experiencia por sí solas no logran explicar. En el modelo, esto se traduce en que al menos algunos de los coeficientes asociados a las variables dummy de posición ocupacional (β_5) y de rama de actividad (β_7) —tomando como referencia “Empleado particular”— sean estadísticamente significativos y distintos de cero.

7. Análisis descriptivo

7.1. Información sobre la base de datos

La base de datos utilizada corresponde a la Gran Encuesta Integrada de Hogares (GEIH), operativo de enero de 2024, publicada por el Departamento Administrativo Nacional de Estadística (DANE). Se utilizan dos de sus módulos:

- **Ocupados:** contiene las variables laborales de las personas ocupadas (ingreso, horas trabajadas, posición ocupacional, antigüedad, rama de actividad, entre otras).
- **Características generales, seguridad social en salud y educación:** contiene las variables demográficas y educativas (edad, nivel educativo, grado aprobado).

Ambos módulos se identifican a nivel de persona mediante las llaves `directorio`, `secuencia_p` y `orden`, por lo que se unen (`left_join`) usando esa combinación.

```
paquetes <- c("dplyr", "car", "ggplot2", "corrplot", "readr", "tidyr", "stringr", "knitr")
instalar <- paquetes[!(paquetes %in% installed.packages()[, "Package"])]
if (length(instalar)) install.packages(instalar)
```

```
library(dplyr)
library(readr)
library(ggplot2)
library(car)
library(corrplot)
library(tidyr)
library(stringr)
library(knitr)
```

Quarto usa como directorio de trabajo la carpeta donde está guardado este archivo `.qmd`. Ajusta `ruta_datos` según dónde tengas los archivos `.CSV` de la GEIH. **Verifica el nombre exacto de la carpeta en tu explorador de archivos** (mayúsculas, guiones y guiones bajos deben coincidir exactamente):

```
# OJO: el nombre debe coincidir EXACTAMENTE con el de la carpeta en Windows,
# incluyendo mayúsculas/minúsculas y el guion "-main" (no guion bajo "_main").
ruta_datos <- "C:/Users/Daniela/Downloads/ModeloSalariosColombianos-main"
```

```
ocupados <- read_csv2(
  file.path(ruta_datos, "Ocupados.CSV"),
  show_col_types = FALSE
)

caracteristicas <- read_csv2(
  file.path(ruta_datos, "Características generales, seguridad social en salud y educación.CSV"),
  show_col_types = FALSE
)
```

```

names(ocupados) <- tolower(names(ocupados))
names(caracteristicas) <- tolower(names(caracteristicas))

llaves <- c("directorio", "secuencia_p", "orden")
stopifnot(all(llaves %in% names(ocupados)))
stopifnot(all(llaves %in% names(caracteristicas)))

datos <- ocupados %>%
  left_join(caracteristicas, by = llaves, relationship = "one-to-one")

# --- Escolaridad (años acumulados) -----
anios_previos <- c(
  "1" = 0, "2" = 0, "3" = 0, "4" = 5, "5" = 9, "6" = 9, "7" = 11,
  "8" = 11, "9" = 13, "10" = 16, "11" = 17, "12" = 19, "13" = 21
)
niveles_semestres <- c("8", "9", "10", "11", "12", "13")

datos <- datos %>%
  mutate(
    nivel_chr = as.character(p3042),
    escolaridad = anios_previos[nivel_chr] +
      ifelse(nivel_chr %in% niveles_semestres,
        coalesce(p3042s1, 0) / 2,
        coalesce(p3042s1, 0)),
    escolaridad = ifelse(nivel_chr %in% c("1", "2"), 0, escolaridad)
  )

# --- Experiencia potencial y su cuadrado -----
datos <- datos %>%
  mutate(
    experiencia = pmax(p6040 - escolaridad - 6, 0),
    experiencia2 = experiencia^2
  )

# --- Log del ingreso -----
datos <- datos %>%
  filter(!is.na(inglabo), inglabo > 0) %>%
  mutate(ln_ingreso = log(inglabo))

# --- Variables categóricas -----
etiquetas_posicion <- c(
  "1" = "Empleado_particular", "2" = "Empleado_gobierno",
  "3" = "Empleado_domestico", "4" = "Cuenta_propia",
  "5" = "Patron_empleador", "6" = "Trab_familiar_sin_remun",
  "7" = "Trab_sin_remun_otros_hogares", "8" = "Jornalero_peon",
  "9" = "Otro"
)

```



```
datos <- datos %>%
  mutate(
    posicion = factor(etiquetas_posicion[as.character(p6430)]),
    rama      = factor(rama2d_r4)
  )
datos$posicion <- relevel(datos$posicion, ref = "Empleado_particular")

# --- Selección y limpieza final -----
datos_modelo <- datos %>%
  rename(horas = p6800, antiguedad = p6426, ingreso = inglabo, edad = p6040) %>%
  select(ingreso, ln_ingreso, horas, edad, escolaridad, experiencia, experiencia2,
         antiguedad, posicion, rama) %>%
  filter(complete.cases(.)) %>%
  filter(horas > 0, horas <= 100,
         escolaridad >= 0, escolaridad <= 25,
         antiguedad >= 0)

poblacion_n <- nrow(datos_modelo)
```

Tras la unión, la construcción de variables y la eliminación de registros incompletos o inconsistentes (horas fuera de rango, escolaridad fuera de rango, etc.), la base analítica de referencia queda con 27327 observaciones.

7.2. Selección de la muestra

Siguiendo la restricción del enunciado (máximo 100 registros), se aplicó un muestreo aleatorio simple (MAS) sobre la base analítica de referencia para obtener una muestra de $n = 100$ observaciones. Bajo este esquema, cada individuo tuvo la misma probabilidad de selección:

$$\pi_i = \frac{n}{N} = \frac{100}{27327}$$

```
set.seed(123)

n_muestra <- 100
muestra <- datos_modelo %>% slice_sample(n = n_muestra)

fraccion_muestreo <- round(n_muestra / poblacion_n * 100, 2)
```

Tabla 2: Parámetros del muestreo aleatorio simple

Parametro	Valor
Población de referencia (N)	27327
Tamaño de muestra (n)	100
Fracción de muestreo (n/N)	0.37 %

Parametro	Valor
Semilla aleatoria	123

7.3. Base consolidada

La base analítica final contiene 100 observaciones y 8 variables: la variable respuesta, cinco covariables continuas (horas, escolaridad, experiencia, experiencia al cuadrado y antigüedad) y dos variables categóricas (posición ocupacional y rama de actividad).

Tabla 3: Primeras diez observaciones de la base consolidada

ln_in- greso	ho- ras	escolari- dad	experien- cia	experien- cia2	antigue- dad	posicion	ra- ma
14.60	50	11.0	28.0	784.00	288	Empleado_gob- bierno	84
14.57	30	19.5	20.5	420.25	0	Empleado_par- ticular	85
14.51	50	14.0	39.0	1521.00	480	Empleado_gob- bierno	86
14.91	47	21.0	31.0	961.00	96	Empleado_gob- bierno	85
13.02	70	6.0	10.0	100.00	24	Cuenta_propia	92
13.30	20	5.0	54.0	2916.00	3	Cuenta_propia	56
14.56	47	13.0	19.0	361.00	60	Empleado_gob- bierno	36
13.82	50	11.0	21.0	441.00	8	Empleado_par- ticular	47
13.65	48	4.0	49.0	2401.00	186	Cuenta_propia	81
15.32	48	21.0	28.0	784.00	336	Empleado_par- ticular	71


7.4. Variable respuesta: logaritmo del ingreso laboral mensual

Tabla 4: Estadísticos descriptivos del logaritmo del ingreso laboral mensual

Medida	Valor
n	100
Media	13.884
Mediana	13.964
Desviación estándar	0.735
Coefficiente de variación	5.3 %
Mínimo	11.695
Primer cuartil (Q1)	13.592
Tercer cuartil (Q3)	14.221

Medida	Valor
Máximo	15.607
Asimetría	-0.625

La Tabla anterior presenta los estadísticos descriptivos de la variable de respuesta ya transformada. En promedio, el log-ingreso de la muestra es de 13.884, con una mediana de 13.964; la cercanía entre ambas medidas y una asimetría de -0.625 son consistentes con el efecto esperado de la transformación logarítmica: corrige buena parte del sesgo positivo propio de la distribución original de los ingresos.



Se muestra el ingreso en su escala original y ya transformado a logaritmo: el histograma de la izquierda evidencia la asimetría positiva característica de los ingresos laborales (unos pocos valores muy altos alargan la cola derecha), mientras que el de la derecha muestra una distribución considerablemente más simétrica, lo que respalda el uso de $\ln(Y)$ como variable de respuesta del modelo.


7.5. Descripción de las covariables continuas

Tabla 5: Estadísticos descriptivos de las covariables continuas ($n = 100$)

Variable	Media	Mediana	DE	Min	Max	Q1	Q3
antigüedad	69.13	24.00	95.76	0	480.0	12.00	84.00
escolaridad	11.72	11.00	5.93	0	23.5	7.75	14.50
experiencia	23.52	20.25	15.51	0	64.0	10.75	34.25
experiencia2	790.98	410.12	905.15	0	4096.0	115.75	1173.25
horas	44.35	47.00	14.44	8	90.0	40.00	48.00


Log(Ingreso) vs horas trabajadas

Correlación de Pearson $r = 0.407$




Log(Ingreso) vs escolaridad (años)

Correlación de Pearson $r = 0.641$




Log(Ingreso) vs experiencia potencial

Correlación de Pearson $r = -0.226$



Log(Ingreso) vs antigüedad (meses)

Correlación de Pearson $r = 0.283$




Las figuras anteriores muestran la relación entre el log-ingreso y cada covariable continua, junto con una curva LOESS y el coeficiente de correlación de Pearson. Conforme a la teoría del capital humano, se espera que la escolaridad y las horas trabajadas muestren las asociaciones positivas más claras; la relación con la experiencia potencial debería aproximarse a una forma

cóncava, coherente con la inclusión de su término cuadrático en el modelo.

Tabla 6: Matriz de correlaciones de Pearson entre las variables continuas

	ln_ingreso	horas	escolaridad	experiencia	antigüedad
ln_ingreso	1.000	0.407	0.641	-0.226	0.283
horas	0.407	1.000	0.109	-0.135	0.218
escolaridad	0.641	0.109	1.000	-0.447	0.176
experiencia	-0.226	-0.135	-0.447	1.000	0.274
antigüedad	0.283	0.218	0.176	0.274	1.000




La matriz de correlaciones permite evaluar, además de la relación con la variable de respuesta, el grado de asociación entre las covariables entre sí — un primer indicio sobre posibles problemas de multicolinealidad que se evaluarán formalmente (VIF) en etapas posteriores del proyecto.

7.6. Descripción de las variables categóricas

7.6.1. Posición ocupacional

Tabla 7: Distribución de la muestra y log-ingreso medio según posición ocupacional (n = 100)

posicion	n	Media_ln_ingreso	Mediana_ln_ingreso
Empleado_particular	42	14.04	13.98
Cuenta_propia	42	13.62	13.77
Empleado_gobierno	8	14.78	14.76
Empleado_domestico	5	13.05	13.42
Trab_sin_remun_otros_hogares	2	14.04	14.04
Patron_empleador	1	15.42	15.42




7.6.2. Rama de actividad económica

Tabla 8: Distribución de la muestra y log-ingreso medio según rama de actividad (n = 100)

rama	n	Media_ln_ingreso	Mediana_ln_ingreso
47	15	13.62	13.82
49	7	13.91	13.96
56	7	13.50	13.46
85	7	14.74	14.73
01	5	14.11	14.00
84	5	14.40	14.29

rama	n	Media_ln_ingreso	Mediana_ln_ingreso
86	5	14.20	14.08
96	5	13.73	13.59
97	5	13.05	13.42
81	4	13.15	13.09
41	3	12.95	13.38
14	2	14.00	14.00
23	2	14.07	14.07
36	2	14.26	14.26
45	2	13.56	13.56
46	2	14.33	14.33
64	2	13.71	13.71
68	2	13.96	13.96
71	2	15.46	15.46
95	2	13.97	13.97
20	1	13.96	13.96
25	1	14.00	14.00
29	1	13.96	13.96
31	1	13.30	13.30
35	1	14.05	14.05
52	1	13.30	13.30
55	1	13.96	13.96
65	1	14.08	14.08
66	1	14.73	14.73
69	1	14.73	14.73
73	1	14.00	14.00
80	1	14.40	14.40
82	1	13.96	13.96
92	1	13.02	13.02



Al tratarse de una muestra de 100 observaciones, es esperable que algunas categorías —tanto de posición ocupacional como de rama de actividad— queden representadas por muy pocas observaciones. Esto deberá tenerse en cuenta al momento de estimar el modelo, evaluando si es necesario agrupar categorías poco frecuentes para evitar coeficientes poco confiables.

8. Modelo matemático propuesto

Con fundamento en la teoría del capital humano y en la especificación clásica de la ecuación de ingresos de Mincer, se propone estimar un modelo de regresión lineal múltiple en el que el logaritmo natural del ingreso laboral mensual constituye la variable dependiente:

$$\ln(Y_i) = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 X_{3i} + \beta_4 X_{4i} + \beta_5 X_{5i} + \beta_6 X_{6i} + \beta_7 X_{7i} + \varepsilon_i$$

donde X_1 : horas trabajadas por semana; X_2 : años de escolaridad; X_3 : experiencia potencial; X_4 : experiencia potencial al cuadrado; X_5 : posición ocupacional (dummy); X_6 : antigüedad en el empleo actual; X_7 : rama de actividad económica (dummy); β_0 : intercepto; ε_i : error aleatorio.

Antes de estimar el modelo definitivo se verificará el cumplimiento de los supuestos de la regresión lineal múltiple, evaluando la existencia de multicolinealidad mediante el Factor de Inflación de la Varianza (VIF), la homocedasticidad de los residuos, la normalidad de los errores y la posible presencia de observaciones influyentes.

9. Conclusiones

El análisis descriptivo confirma que la transformación logarítmica del ingreso laboral corrige de forma considerable la asimetría propia de esta variable, lo que respalda su uso como variable de respuesta del modelo. Las covariables continuas —en particular escolaridad y horas trabajadas— muestran las asociaciones esperadas con el log-ingreso según la teoría del capital humano, mientras que la posición ocupacional y la rama de actividad evidencian diferencias en el nivel medio de ingreso entre categorías, lo que sugiere que ambas variables aportan información relevante para el modelo más allá de la escolaridad y la experiencia.

Al mismo tiempo, el análisis muestra que ninguna covariable por sí sola explica la totalidad de la variabilidad del ingreso, lo que anticipa que sus efectos deberán evaluarse de forma conjunta en un modelo de regresión múltiple, prestando especial atención a la multicolinealidad entre escolaridad y experiencia (ambas derivadas de la edad y el nivel educativo) y a las categorías con pocas observaciones dentro de posición ocupacional y rama de actividad.

Referencias

- [1] Mincer, J. (1974). *Schooling, Experience, and Earnings*. Columbia University Press.
- [2] Núñez, J. & Sánchez, F. (1998). Educación y salarios relativos en Colombia, 1976-1995: Determinantes, evolución e implicaciones para la distribución del ingreso. *Archivos de Macroeconomía*, No. 74. Departamento Nacional de Planeación, Bogotá.
- [3] Guataquí, J. C., García, A. & Rodríguez, M. Estimaciones de los determinantes de los ingresos laborales en Colombia. Banco de la República.
- [4] Banco de la República (2021). Desigualdades del ingreso en Colombia: ¿cuáles son sus determinantes y cómo se han afectado por la pandemia del Covid-19? *Ensayos sobre Política Económica*, No. 101.
- [5] Determinantes de los ingresos laborales de los economistas en Colombia: un análisis de modelación microeconómica (2019). *Panorama Económico*, Universidad de Cartagena.