



Universidad Nacional de Colombia
Departamento de Estadística – Facultad de Ciencias

Análisis de Regresión – 3006918

**MODELADO DE LOS INGRESOS MENSUALES DE EMPLEADOS EN
COLOMBIA**

Aplicación de un Modelo de Regresión Lineal Múltiple

Docente: Isabel Cristina Ramírez Guevara

Yuliany Cifuentes Rondon
Daniela Cataño Hernández
Samir Alejandro Centeno Torrado

Medellín, Colombia – Semestre 2026-1

Índice

1	Enunciado del proyecto	4
2	Introducción	4
3	Contextualización del problema	4
4	Objetivo general	5
5	Relevancia del estudio	5
5.1	Variables seleccionadas	6
5.1.1	Descripción detallada de las variables	6
6	Modelo matemático propuesto	7
6.1	Hipótesis	7
7	Análisis descriptivo	8
7.1	Información sobre la base de datos	8
7.2	Selección de la muestra	10
7.3	Base consolidada	10
7.4	Variable respuesta: logaritmo del ingreso laboral mensual	11
7.5	Descripción de las covariables continuas	12
7.6	Descripción de la variable categórica	17
7.6.1	Rama de actividad económica	17
8	1. Estimación del modelo con covariables continuas	18
8.1	Ajuste del modelo	18
8.2	ANOVA del modelo	19
8.3	Interpretación	20
9	2. Selección de modelos (covariables continuas)	21
9.1	a) Selección por R_{adj}^2	21
9.2	b) Selección por C_p de Mallows	21
9.3	c) Stepwise (ambas direcciones, AIC)	22
9.4	d) Selección hacia adelante (Forward)	23
9.5	e) Selección hacia atrás (Backward)	23
9.6	Conclusión sobre la selección de modelos	24
10	3. Diagnóstico de supuestos y elección final del modelo	25
11	4. Coeficientes de regresión estandarizados	26
12	5. Prueba de significancia individual de los parámetros	26

13 6. Prueba de suma de cuadrados extra (test lineal general)	27
14 7. Observaciones atípicas, de balanceo e influyentes	29
14.1 Modelo sugerido	29
15 8. Efecto de observaciones atípicas (sensibilidad del modelo)	30
16 9. Diagnósticos de multicolinealidad	32
16.1 a) Matriz de correlación de las variables predictoras	32
16.2 b) Factores de Inflación de la Varianza (VIF)	32
16.3 c) y d) Proporciones de varianza, índices y número de condición	32
17 10. Intervalos de confianza y predicción	33
17.1 Interpretación	33
18 11. Respuesta a las hipótesis planteadas	34
18.1 Hipótesis 1: la escolaridad y la edad explican una parte sustancial de la variabilidad del ingreso laboral	34
18.2 Hipótesis 2: la rama de actividad económica genera diferencias sistemáticas en el ingreso, incluso después de considerar escolaridad y edad	34
19 Conclusiones	35

1. Enunciado del proyecto

El proyecto consiste en buscar una base de datos con datos colombianos que contenga una variable de respuesta continua (), al menos cinco covariables continuas () y una variable categórica () con al menos tres categorías. Los análisis se realizan con máximo 100 registros. El proyecto tiene tres entregas y una exposición final.

1. Contextualizar el fenómeno a modelar: explicar el significado de la variable de respuesta y las covariables, la relevancia del estudio y su objetivo. Establecer dos hipótesis que se desean probar con el modelo.
2. Realizar un análisis descriptivo exhaustivo y pertinente para el tipo de modelo que se va a aplicar.

2. Introducción

El ingreso laboral es uno de los principales determinantes del bienestar de los hogares colombianos y uno de los indicadores mas utilizados para analizar la desigualdad económica del país. Explicar por qué unos trabajadores ganan mas que otros es una pregunta central de la economía laboral y la respuesta habitual —propuesta por Mincer (1974)— es que el ingreso depende principalmente de la acumulacion de capital humano (educacion y experiencia), de la intensidad con que se trabaja (horas) y de las características del empleo (tipo de vinculación y sector económico).

En Colombia, donde la informalidad laboral y la heterogeneidad sectorial son altas, estos factores no siempre se traducen en el mismo nivel de ingreso: dos personas con la misma escolaridad pueden percibir remuneraciones muy distintas segun su posición ocupacional o la rama de actividad en la que trabajan. Este proyecto busca cuantificar, a partir de microdatos de la Gran Encuesta Integrada de Hogares (GEIH), qué tanto explican estas variables la variabilidad del ingreso laboral mensual.

3. Contextualización del problema

El ingreso laboral es una de las variables centrales para el estudio del bienestar economico y del funcionamiento del mercado de trabajo. Desde la teoria del capital humano propuesta originalmente por Mincer, se plantea que el salario de un individuo puede explicarse en buena medida por su nivel de escolaridad y por su experiencia laboral entendida esta ultima como una proxy del entrenamiento adquirido en el puesto de trabajo [1]. Este marco teorico dio origen a la conocida *ecuación de Mincer*, que modela el logaritmo del ingreso como funcion lineal de la educación y de la experiencia (y su forma cuadratica) y que constituye hasta hoy el punto de partida estandar para el analisis empirico de los determinantes salariales.

En el caso colombiano, esta relacion ha sido documentada de manera consistente. Núñez y Sánchez [5] utilizando informacion de encuestas de hogares del DANE encuentran que la escolaridad ha sido el factor con mayor poder explicativo sobre los diferenciales de ingreso laboral en el pais, y que su efecto se ha mantenido estable a lo largo de distintos periodos. En la misma linea Guataquí et al. [2], con datos de la Gran Encuesta Integrada de Hogares

(GEIH), muestran que además de la educación, variables como la posición ocupacional y la experiencia potencial explican una parte relevante de la heterogeneidad salarial observada, y advierten sobre la importancia de separar estos efectos entre asalariados y trabajadores por cuenta propia, dado que ambos grupos responden a estructuras de determinación de ingresos distintas.

Estudios más recientes del banco de la república [3] confirman que estos patrones persisten e incluso se intensifican en contextos de choques económicos: al modelar los determinantes del ingreso laboral para el periodo 2010-2019, encuentran que la brecha salarial asociada al sexo del trabajador y a la posición ocupacional continua siendo estadísticamente significativa una vez controlado por nivel educativo. A nivel de subgrupos poblacionales específicos, Panorama Económico [4] aplica una ecuación minceriana a profesionales en economía y encuentra que un año adicional de formación escolar incrementa significativamente la probabilidad de percibir ingresos más altos evidenciando que el efecto de la educación sobre el salario no es homogéneo entre grupos ocupacionales, sino que varía según el perfil profesional analizado.

En conjunto, esta literatura sugiere que un modelo del ingreso laboral en Colombia debe incorporar como mínimo variables asociadas a la educación, la experiencia o antigüedad laboral y la heterogeneidad sectorial del mercado de trabajo dado que son los determinantes que de manera recurrente resultan significativos en los estudios previos. El presente proyecto retoma este marco para proponer un modelo de regresión lineal múltiple sobre una muestra de trabajadores colombianos, incorporando la escolaridad, la edad (y su término cuadrático), la antigüedad en el empleo actual y la intensidad de trabajo (horas semanales) como covariables continuas y la rama de actividad económica como variable categórica, con el fin de evaluar el peso relativo de estos factores sobre el ingreso laboral.

4. Objetivo general

Desarrollar un modelo de regresión lineal múltiple que permita explicar el logaritmo del ingreso laboral mensual de los trabajadores en Colombia a partir de variables asociadas a la teoría del capital humano y a la literatura empírica sobre determinantes salariales en el país específicamente las horas de trabajo semanales, la escolaridad, la edad, la antigüedad en el empleo actual y la rama de actividad económica en la que se desempeña el trabajador.

5. Relevancia del estudio

La identificación de los factores que determinan los ingresos laborales es un tema central en la economía laboral y ha sido ampliamente estudiado en Colombia desde la perspectiva del capital humano [1, 5]. Sin embargo, buena parte de esta literatura se ha concentrado en variables de escolaridad y experiencia, dejando en un segundo plano el análisis conjunto con variables como la intensidad y continuidad laboral (horas trabajadas y antigüedad en el empleo actual). Este proyecto busca aportar evidencia adicional sobre el peso relativo de estos factores frente a los determinantes tradicionales, replicando además la evidencia existente sobre las diferencias de ingreso asociadas a la rama de actividad económica documentadas por el banco de la república [3]. Los resultados permitirán establecer que características tienen una influencia significativa

sobre los salarios en la muestra analizada y contrastar estos hallazgos con lo reportado en la literatura previa.

5.1. Variables seleccionadas

Tabla 1: Variables seleccionadas, rol en el modelo y significado en el estudio.

Nombre	Código	Rol	Tipo	Significado
Logaritmo del ingreso laboral mensual	INGLABO (transformada)	Y	Continua	Ingreso laboral mensual transformado a escala logarítmica para reducir la asimetría de la distribución.
Horas trabajadas por semana	P6800	X1	Continua	Intensidad del trabajo desarrollado durante la semana de referencia.
Años de escolaridad	P3042 (recodificada)	X2	Continua	Años de educación formal aprobados, recodificados a partir del nivel educativo alcanzado; mide la acumulación de capital humano.
Edad	P6040	X3	Continua	Edad de la persona en años cumplidos; aproxima el ciclo de vida laboral.
Edad al cuadrado	Derivada de X3	X4	Continua	Captura el efecto no lineal (rendimientos decrecientes) de la edad sobre el ingreso.
Antigüedad en el empleo actual	P6426	X5	Continua	Meses en el empleo u ocupación actual; aproxima estabilidad y experiencia específica.
Rama de actividad económica	RAMA2D_R4	X6 (Z)	Categorica	Sector económico (CIU, 2 dígitos) en el que se desempeña el trabajador.

5.1.1. Descripción detallada de las variables

Y: Logaritmo del ingreso laboral mensual. La variable de respuesta corresponde al ingreso laboral mensual percibido por las personas ocupadas incluidas en la GEIH, expresado en pesos colombianos. Dado que en economía laboral es ampliamente reconocido que la distribución de los ingresos presenta una marcada asimetría positiva la variable dependiente se transforma mediante el logaritmo natural, lo que reduce la asimetría disminuye la influencia de valores extremos y permite interpretar los coeficientes del modelo como variaciones porcentuales aproximadas del ingreso (especificación clásica de Mincer, 1974).

X1: Horas trabajadas por semana. Número de horas que la persona trabajo habitualmente durante la semana de referencia en su ocupación principal. Se espera una relación positiva con el ingreso.

X2: Años de escolaridad. Construida a partir del nivel educativo alcanzado (P3042), recodificando cada uno de los 13 niveles a un número típico de años acumulados de educación formal. Para los niveles hasta la educación media los años corresponden a la duración legal establecida por la Ley 115 de 1994 (primaria: 5 años; básica secundaria: 4 años adicionales; media: 2 años adicionales). Para los niveles de educación superior (técnica, tecnológica, universitaria y posgrados), se asume la duración típica de cada programa, siguiendo la convención de conversión utilizada en estudios de determinantes salariales con la GEIH [5], dado que la encuesta no permite distinguir la duración exacta cursada por cada persona dentro de ese nivel.

X3: Edad. Edad de la persona en años cumplidos al momento de la encuesta. Se utiliza como proxy del ciclo de vida laboral en lugar de la experiencia potencial (Edad - Escolaridad - 6), evitando así que esta covariable dependa de la variable de escolaridad ya construida y reduciendo el número de transformaciones y supuestos encadenados sobre la base de datos.

X4: Edad al cuadrado. Incorpora la relación cóncava entre edad e ingreso: los ingresos aumentan con la edad pero a una tasa decreciente, consistente con el perfil edad-ingreso documentado en la literatura de capital humano.

X5: Antigüedad en el empleo actual. Meses que el trabajador lleva en su empleo u ocupación actual; aproxima estabilidad laboral y experiencia específica en la organización.

X6 (Z): Rama de actividad económica. Sector económico en el que se desempeña el trabajador agrupado según la Clasificación Industrial Internacional Uniforme (CIIU) a 2 dígitos.

6. Modelo matemático propuesto

Con fundamento en la teoría del capital humano y en la especificación clásica de la ecuación de ingresos de Mincer se propone estimar un modelo de regresión lineal múltiple en el que el logaritmo natural del ingreso laboral mensual constituye la variable dependiente:

$$\ln(Y_i) = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 X_{3i} + \beta_4 X_{4i} + \beta_5 X_{5i} + \beta_6 X_{6i} + \varepsilon_i$$

donde X_1 : horas trabajadas por semana; X_2 : años de escolaridad; X_3 : edad; X_4 : edad al cuadrado; X_5 : antigüedad en el empleo actual; X_6 : rama de actividad económica (dummy); β_0 : intercepto; ε_i : error aleatorio.

Antes de estimar el modelo definitivo se verificara el cumplimiento de los supuestos de la regresión lineal múltiple, evaluando la existencia de multicolinealidad mediante el Factor de Inflación de la Varianza (VIF), la homocedasticidad de los residuos, la normalidad de los errores y la posible presencia de observaciones influyentes [6].

6.1. Hipótesis

Las siguientes hipótesis se desprenden directamente de la contextualización presentada en la Introducción y la Relevancia (teoría del capital humano de Mincer, 1974, y la heterogeneidad del mercado laboral colombiano). Cada una se plantea de forma que pueda traducirse, en la etapa de modelación, en el signo y la significancia esperados de parámetros específicos del modelo $\ln(Y_i) = \beta_0 + \beta_1 X_{1i} + \dots + \beta_6 X_{6i} + \varepsilon_i$.

Hipótesis 1: la escolaridad y la edad explican una parte sustancial de la variabilidad del ingreso laboral. De acuerdo con la teoría del capital humano, se espera que los trabajadores con mayor escolaridad perciban ingresos más altos, y que el ingreso siga un perfil cóncavo respecto a la edad —creciente en las primeras etapas de la vida laboral hasta el punto en que los rendimientos empiezan a decrecer—. En términos del modelo, esta hipótesis se traduce en $\beta_2 > 0$ (escolaridad), $\beta_3 > 0$ (edad) y $\beta_4 < 0$ (edad al cuadrado), reflejando el

perfil cóncavo típico de la ecuación de Mincer. Se espera además que ambos coeficientes sean estadísticamente significativos.

Hipótesis 2: la rama de actividad económica genera diferencias sistemáticas en el ingreso, incluso después de considerar la escolaridad y la edad. Dada la heterogeneidad e informalidad del mercado laboral colombiano descrita en la Relevancia, se espera que existan brechas de ingreso entre sectores económicos que la educación y la edad por sí solas no logran explicar. En el modelo, esto se traduce en que al menos algunos de los coeficientes asociados a las variables dummy de rama de actividad (β_6) sean estadísticamente significativos y distintos de cero.

7. Análisis descriptivo

7.1. Información sobre la base de datos

La base de datos utilizada corresponde a la Gran Encuesta Integrada de Hogares (GEIH), operativo de enero de 2024, publicada por el Departamento Administrativo Nacional de Estadística (DANE). Los microdatos se descargaron en formato .zip desde el archivo nacional de microdatos del DANE (operativo de enero): <https://microdatos.dane.gov.co/index.php/catalog/819/data-dictionary>. Se utilizan dos de sus módulos:

- **Ocupados:** contiene las variables laborales de las personas ocupadas (ingreso, horas trabajadas, antigüedad, rama de actividad, entre otras).
- **Características generales, seguridad social en salud y educación:** contiene las variables demográficas y educativas (edad, nivel educativo, grado aprobado).

Ambos módulos se identifican a nivel de persona mediante las llaves `directorio`, `secuencia_p` y `orden`, por lo que se unen (`left_join`) usando esa combinación.

```
# --- escolaridad (años acumulados) -----
# Recodificación de una sola variable (P3042: nivel educativo alcanzado) a años típicos de e
anios_tipicos <- c(
  "1" = 0, "2" = 0, "3" = 5, "4" = 9, "5" = 11, "6" = 11,
  "7" = 13, "8" = 13, "9" = 14, "10" = 16, "11" = 17, "12" = 18, "13" = 21
)

datos <- datos %>%
  mutate(
    p3042_chr = as.character(p3042),
    escolaridad = anios_tipicos[p3042_chr]
  )

# --- edad y edad al cuadrado -----
# Se usa la edad directamente (sin transformar) como proxy del ciclo de vida laboral en luga

datos <- datos %>%
  mutate(
```



```

    edad2 = p6040^2
  )

# --- log del ingreso -----
datos <- datos %>%
  filter(!is.na(inglabo), inglabo > 0) %>%
  mutate(ln_ingreso = log(inglabo))

# --- variable categorica -----

# --- rama de actividad economica (recodificada a sectores agregados) -----
# Se clasifica por rango de codigo CIIU (2 dígitos) en vez de una tabla de busqueda exhaustiva
datos <- datos %>%
  mutate(
    rama2d_num = as.numeric(as.character(rama2d_r4)),
    rama = case_when(
      rama2d_num >= 1 & rama2d_num <= 3 ~ "Agropecuario",
      rama2d_num >= 5 & rama2d_num <= 43 ~ "Industria_mineria_construccion",
      rama2d_num >= 45 & rama2d_num <= 56 ~ "Comercio_transporte_alojamiento",
      rama2d_num >= 58 & rama2d_num <= 82 ~ "Servicios_financ_profesionales",
      rama2d_num >= 84 & rama2d_num <= 99 ~ "Servicios_sociales_otros",
      TRUE ~ NA_character_
    ),
    rama = factor(rama)
  )

# --- Seleccion y limpieza final -----
datos_modelo <- datos %>%
  rename(horas = p6800, antiguedad = p6426, ingreso = inglabo, edad = p6040) %>%
  select(ingreso, ln_ingreso, horas, edad, edad2, escolaridad,
    antiguedad, rama) %>%
  filter(complete.cases(.)) %>%
  filter(horas > 0, horas <= 100,
    escolaridad >= 0, escolaridad <= 25,
    edad >= 18, edad <= 80,
    antiguedad >= 0)

poblacion_n <- nrow(datos_modelo)

```

Tras la union, la construcción de variables y la eliminacion de registros incompletos o inconsistentes (horas fuera de rango, escolaridad fuera de rango, etc.) la base analítica de referencia queda con 27128 observaciones

La variable rama de actividad económica se construyó originalmente a partir de la clasificación CIIU a 2 dígitos (rama2d_r4), la cual presenta 36 categorías distintas en la muestra de 100 observaciones, 18 de ellas representadas por un único individuo. Dado que esta granularidad hace inviable estimar coeficientes confiables para cada categoría, se recodificó la variable en cinco sectores agregados —Agropecuario; Industria, minería y construcción; Comercio,

transporte y alojamiento; Servicios financieros y profesionales; y Servicios sociales, comunales y otros— siguiendo la agrupación estandar de secciones de la Clasificación Industrial Internacional Uniforme (CIIU Rev. 4, adaptada por el DANE). Esta recodificación conserva la interpretación económica de la variable como proxy de heterogeneidad sectorial, a la vez que garantiza un tamaño muestral mínimo razonable por categoría (entre 11 y 33 observaciones) para la etapa de estimación del modelo.

7.2. Selección de la muestra

Siguiendo la restricción del enunciado (máximo 100 registros), se aplicó un muestreo aleatorio simple (MAS) sobre la base analítica de referencia para obtener una muestra de $n = 100$ observaciones, fijando la semilla aleatoria en 123 para garantizar la reproducibilidad del muestreo. Bajo este esquema, cada individuo tuvo la misma probabilidad de selección:

$$\pi_i = \frac{n}{N} = \frac{100}{27128}$$

Tabla 2: parámetros del muestreo aleatorio simple

Parámetro	Valor
población de referencia (N)	27128
Tamaño de muestra (n)	100
fracción de muestreo (n/N)	0.37 %
semilla aleatoria	123

7.3. Base consolidada

La base analítica final contiene 100 observaciones y 7 variables: la variable respuesta, cinco covariables continuas (horas, escolaridad, edad, edad al cuadrado y antigüedad) y una variable categórica (rama de actividad económica).

Tabla 3: Primeras diez observaciones de la base consolidada

ln_ingre- so	horas	escolaridad	edad	edad2	antigüe- dad	rama
13.12	48	16	26	676	12	Industria_mineria_construc- cion
12.77	20	5	38	1444	120	Servicios_financ_profesiona- les
14.81	50	5	55	3025	11	Agropecuario
14.08	48	9	54	2916	2	Comercio_transporte_aloja- miento
14.85	40	16	34	1156	36	Servicios_sociales_otros
14.22	40	17	39	1521	168	Servicios_sociales_otros
14.65	36	17	39	1521	120	Servicios_sociales_otros


ln_ingre- so	horas	escolaridad	edad	edad2	antigüe- dad	rama
14.62	48	13	23	529	18	Comercio_transporte_aloja- miento
13.12	48	11	37	1369	120	Agropecuario
14.51	30	11	36	1296	120	Comercio_transporte_aloja- miento

7.4. Variable respuesta: logaritmo del ingreso laboral mensual

Tabla 4: Estadísticos descriptivos del logaritmo del ingreso laboral mensual

Medida	Valor
n	100
Media	13.826
Mediana	13.964
Desviación estándar	0.95
Coefficiente de variación	6.9 %
Mínimo	10.597
Primer cuartil (Q1)	13.305
Tercer cuartil (Q3)	14.287
Máximo	15.83
Asimetría	-0.785

La Tabla anterior presenta los estadísticos descriptivos de la variable de respuesta ya transformada. En promedio el log-ingreso de la muestra es de 13.826, con una mediana de 13.964. la cercanía entre ambas medidas y una asimetría de -0.785 son consistentes con el efecto esperado de la transformación logarítmica: corrige buena parte del sesgo positivo propio de la distribución original de los ingresos.



se muestra el ingreso en su escala original y ya transformado a logaritmo: el histograma de la izquierda evidencia la asimetría positiva característica de los ingresos laborales (unos pocos valores muy altos alargan la cola derecha) mientras que el de la derecha muestra una distribución considerablemente más simétrica, lo que respalda el uso de $\ln(Y)$ como variable de respuesta del modelo.

7.5. Descripción de las covariables continuas

Tabla 5: Estadísticos descriptivos de las covariables continuas ($n = 100$)

Variable	Media	Mediana	DE	Min	Max	Q1	Q3
antigüedad	78.19	36.0	93.26	0	480	12	120
edad	41.38	39.0	12.81	19	71	32	50
edad2	1874.86	1521.0	1144.50	361	5041	1024	2500
escolaridad	11.18	11.0	4.29	0	18	9	14
horas	42.78	47.5	13.96	3	76	40	48

La Tabla 5 muestra asimetrías marcadas entre las covariables continuas. La antigüedad es la más sesgada: su media (78.19 meses) casi duplica su mediana (36 meses) y su desviación estándar (93.26) supera a la propia media lo que indica una fuerte cola derecha — la mayoría de los trabajadores lleva poco tiempo en su empleo actual ($Q1 = 12$ meses, $Q3 = 120$ meses) pero un grupo reducido con antigüedades de hasta 480 meses (40 años) arrastra el promedio hacia arriba. La edad en cambio presenta media y mediana cercanas (41.38 y 39 años) y una dispersión moderada ($DE = 12.81$) consistente con una distribución razonablemente simétrica en el rango de vida laboral activa (19-71 años). La escolaridad también es prácticamente simétrica (media 11.18, mediana 11 años), con la mitad central de la muestra ($Q1$ - $Q3$) situada entre 9 y 14 años, es decir, entre bachillerato incompleto y estudios técnicos o tecnológicos. Las horas trabajadas muestran una mediana (47.5) superior a la media (42.78), lo que sugiere una cola hacia valores bajos: la mayoría trabaja entre 40 y 48 horas semanales ($Q1$ - $Q3$), pero algunos casos de jornadas muy reducidas (mínimo de 3 horas) bajan el promedio general.




Figura 1: Log(Ingreso) vs. horas trabajadas por semana




Figura 2: Log(Ingreso) vs. años de escolaridad




Figura 3: Log(Ingreso) vs. edad




Figura 4: Log(Ingreso) vs. antigüedad en el empleo actual

Las Figura 1 a Figura 4 muestran la relación entre el log-ingreso y cada covariable continua junto con una curva LOESS y el coeficiente de correlación de Pearson. La escolaridad presenta la asociación lineal más fuerte con el log-ingreso ($r=0.489$ $r = 0.489$ $r=0.489$) con una tendencia creciente y particularmente pronunciada en los niveles mas altos de educación, consistente con los rendimientos crecientes a la educación superior documentados en la literatura. Las horas trabajadas muestran una asociación positiva moderada ($r=0.350$ $r = 0.350$ $r=0.350$), aunque la curva LOESS evidencia un aplanamiento a partir de las 40 horas semanales: superado ese umbral trabajar mas horas no se traduce en incrementos proporcionales del ingreso. La antigüedad exhibe una correlación lineal debil ($r=0.104$ $r = 0.104$ $r=0.104$), con la mayoría de las observaciones concentradas en valores bajos y un leve repunte solo en los casos de mayor antigüedad. La edad es el caso mas particular: su correlación de Pearson es practicamente nula ($r=-0.041$ $r = -0.041$ $r=-0.041$), pero la curva LOESS si insinua el perfil cóncavo esperado por la teoría del capital humano —un leve ascenso hasta la quinta decada de vida seguido de un descenso—, lo que confirma que la relacion no es de tipo lineal y respalda la inclusion del término cuadrático (edad²) en el modelo en lugar de depender unicamente del coeficiente de correlación simple.

Se observa que los puntos de la Figura 2 se agrupan en un número reducido de valores discretos (0, 5, 9, 11, 13, 14, 16, 17, 18 y 21 años) en lugar de distribuirse de forma continua. Esto es consecuencia directa del metodo de construccion de la variable: al no preguntarse en la GEIH el numero exacto de años cursados sino el nivel educativo alcanzado, la escolaridad se aproxima mediante la duración típica asociada a cada nivel (Ley 115 de 1994 y convención de Núñez y Sánchez [5]). Se trata, por tanto de una variable discreta con una escala de intervalo bien definida tratada como continua siguiendo la convención estándar en la literatura de determinantes salariales, en la que “años de escolaridad” se modela habitualmente como covariable continua pese a su naturaleza discreta [1, 5].

Tabla 6: Matriz de correlaciones de Pearson entre las variables continuas

	ln_ingreso	horas	escolaridad	edad	antigüedad
ln_ingreso	1.000	0.350	0.489	-0.041	0.104
horas	0.350	1.000	-0.012	-0.093	-0.313
escolaridad	0.489	-0.012	1.000	-0.233	0.038
edad	-0.041	-0.093	-0.233	1.000	0.381
antigüedad	0.104	-0.313	0.038	0.381	1.000




Figura 5: Matriz de correlaciones de Pearson entre las variables continuas (representación gráfica)

La Tabla 6 y la Figura 5 confirman la jerarquía observada en los diagramas de dispersión: la escolaridad (0.489) y las horas trabajadas (0.350) son las covariables más asociadas linealmente con el log-ingreso seguidas de la antigüedad (0.104) y la edad (-0.041). En cuanto a la asociación entre covariables la mayor correlación se presenta entre edad y antigüedad ($r=0.381$) lo cual es esperable dado que ambas están ligadas al ciclo de vida laboral también destaca una correlación negativa moderada entre horas trabajadas y antigüedad ($r=-0.313$) y entre escolaridad y edad ($r=-0.233$) esta última consistente con la expansión histórica del acceso a la educación en Colombia que ha elevado la escolaridad promedio de las cohortes más jóvenes frente a las de mayor edad. Ninguna de estas correlaciones supera el umbral de 0.5 usualmente considerado como señal de alerta temprana de multicolinealidad severa aunque la asociación entre edad y antigüedad es la que ameritaría mayor atención al calcular los VIF en la etapa de estimación del modelo.

7.6. Descripción de la variable categórica

7.6.1. Rama de actividad económica

Tabla 7: Distribución de la muestra y log-ingreso medio según sector económico agregado (n = 100)

rama	n	Media_ln_ingreso	Mediana_ln_ingreso
Comercio_transporte_alojamiento	33	13.78	13.96
Servicios_sociales_otros	24	14.19	14.11
Industria_mineria_construccion	20	13.94	14.02
Agropecuario	12	13.21	13.21
Servicios_financ_profesionales	11	13.61	13.96

La recodificación en cinco sectores agregados produjo una distribución mucho más manejable que la original: el grupo más grande, comercio, transporte y alojamiento, concentra 33 observaciones seguido de servicios sociales y otros (24) e industria, minería y construcción (20) agropecuario reúne 12 observaciones y servicios financieros y profesionales, el grupo más pequeño queda con 11 — sensiblemente mejor que los 18 grupos con una sola observación que tenía la codificación original, aunque este último grupo sigue siendo el más vulnerable a la inestabilidad muestral y deberá vigilarse en la etapa de estimación (por ejemplo, revisando su apalancamiento e influencia sobre el modelo). En cuanto al log-ingreso medio, Servicios sociales y otros presenta el valor más alto (media 14.19, mediana 14.11), seguido de cerca por Industria, minería y construcción (13.94 y 14.02); en el otro extremo Agropecuario registra el log-ingreso medio más bajo (13.21, mediana 13.21). Comercio, transporte y alojamiento — pese a ser el sector con más observaciones — y Servicios financieros y profesionales quedan en un nivel intermedio, con medias de 13.78 y 13.61 respectivamente, y medianas prácticamente iguales (13.96 en ambos casos).




Figura 6: Log(Ingreso) según sector económico agregado

La Figura 6 confirma la heterogeneidad sectorial sugerida por la Tabla 7 (note que el eje horizontal ordena los sectores alfabeticamente y no por tamaño muestral). Servicios sociales y otros presenta la mediana mas alta y la caja mas compacta de los cinco sectores —es decir la menor dispersión en el 50% central de sus datos— aunque exhibe dos valores atipicos: uno muy alto el mayor de toda la muestra, y otro bajo que amplian su rango total pese a la estrechez de la caja. Industria, minería y construcción tiene la segunda mediana mas alta y a diferencia del sector anterior no presenta valores atipicos, si bien sus bigotes cubren un rango amplio. Comercio, transporte y alojamiento y Servicios financieros y profesionales muestran medianas muy similares entre si y ligeramente por debajo de Industria, consistentes con el empate observado en la Tabla 7 (13.96 en ambos casos); el primero registra dos valores atipicos bajos y el segundo uno solo más extremo, que corresponde al valor minimo de toda la muestra. Agropecuario registra la mediana mas baja de los cinco sectores y la caja de mayor altura, lo que indica una mayor heterogeneidad interna en su 50% central, sin valores atipicos marcados. En conjunto la brecha entre el sector con mayor log-ingreso medio (Servicios sociales y otros, 14.19) y el de menor log-ingreso medio (Agropecuario, 13.21) es de 0.98 puntos en escala logarítmica, una diferencia sustancial que respalda la Hipótesis 2 sobre la existencia de brechas de ingreso asociadas al sector económico aunque su significancia estadística formal debiera confirmarse en la etapa de estimación del modelo controlando por escolaridad, edad, horas trabajadas y antigüedad.

8. 1. Estimación del modelo con covariables continuas

8.1. Ajuste del modelo

Call:

```
lm(formula = ln_ingreso ~ horas + escolaridad + edad + edad2 +
    antigüedad, data = muestra)
```

Residuals:

```
      Min       1Q   Median       3Q      Max
-2.43540 -0.36965  0.03507  0.45412  1.90504
```

Coefficients:

```
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.097e+01  8.028e-01  13.659 < 2e-16 ***
horas        2.871e-02  5.728e-03   5.012 2.52e-06 ***
escolaridad  1.093e-01  1.834e-02   5.957 4.42e-08 ***
edad         9.561e-03  3.676e-02   0.260  0.7953
edad2       -7.814e-05  4.112e-04  -0.190  0.8497
antigüedad   2.064e-03  9.260e-04   2.228  0.0282 *
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.7487 on 94 degrees of freedom

Multiple R-squared: 0.4106, Adjusted R-squared: 0.3793

F-statistic: 13.1 on 5 and 94 DF, p-value: 1.122e-09

Tabla 8: Parámetros estimados del modelo con covariables continuas

Parámetro	Estimación	Error estándar	t	p-valor
(Intercept)	10.9656	0.8028	13.659	0.0000
horas	0.0287	0.0057	5.012	0.0000
escolaridad	0.1093	0.0183	5.957	0.0000
edad	0.0096	0.0368	0.260	0.7953
edad2	-0.0001	0.0004	-0.190	0.8497
antigüedad	0.0021	0.0009	2.228	0.0282

La ecuación ajustada es:

$$\widehat{\ln(Y_i)} = 10.97 + 0.0287 X_{1i} + 0.1093 X_{2i} + 0.0096 X_{3i} - 0.000078 X_{4i} + 0.00206 X_{5i}$$

donde X_1 : horas, X_2 : escolaridad, X_3 : edad, X_4 : edad², X_5 : antigüedad.

8.2. ANOVA del modelo

Tabla 9: Tabla ANOVA del modelo con covariables continuas

Fuente	Df	Sum Sq	Mean Sq	F value	Pr(>F)
horas	1	10.9825	10.9825	19.5908	0.0000
escolaridad	1	21.7831	21.7831	38.8570	0.0000
edad	1	1.0994	1.0994	1.9611	0.1647
edad2	1	0.0627	0.0627	0.1118	0.7388
antigüedad	1	2.7839	2.7839	4.9660	0.0282
Residuals	94	52.6961	0.5606	NA	NA

El estadístico F global es de 13.097 con 5 y 94 grados de libertad, con un p-valor de 1.12e-09. El modelo explica el 41.06 % de la variabilidad total del log-ingreso ($R^2 = 0.4106$; R^2 ajustado = 0.3793).

8.3. Interpretación

El modelo resulta globalmente significativo: la prueba F rechaza la hipótesis nula de que todos los coeficientes de pendiente son simultáneamente iguales a cero, con un p-valor prácticamente nulo. Esto indica que al menos una de las covariables incluidas tiene poder explicativo real sobre el log-ingreso laboral. Sin embargo la significancia global no implica que todas las variables individuales aporten de manera equivalente. El análisis de los coeficientes muestra que horas trabajadas, escolaridad y antigüedad son significativas al 5 %, esta última en el límite ($p=0.028$, $p=0.028$, $p=0.028$) mientras que edad y edad² no resultan significativas ($p=0.795$, $p=0.795$, $p=0.795$ y $p=0.850$, $p=0.850$, $p=0.850$, respectivamente). Este resultado es consistente con lo observado en el análisis descriptivo (Tabla 7) donde la correlación de Pearson entre edad y log-ingreso era prácticamente nula ($r=-0.041$, $r=-0.041$, $r=-0.041$) si bien la curva LOESS sugería un perfil cóncavo dicho efecto no logra sostenerse estadísticamente una vez controlado por las demás variables posiblemente por el tamaño muestral ($n=100$, $n=100$, $n=100$). Este hallazgo matiza la Hipótesis 1: el componente de escolaridad se confirma ($\beta_2 > 0$, $\beta_2 > 0$, $\beta_2 > 0$, $p < 0.001$, $p < 0.001$, $p < 0.001$), pero el componente de edad no encuentra soporte en este modelo reducido. En cuanto al 41.06 % de la variabilidad explicada (R^2), su interpretación requiere contexto. En estudios de corte transversal sobre ingresos laborales con datos de encuestas de hogares, valores de R^2 entre 0.20 y 0.40 son habituales en ecuaciones de tipo Mincer basadas en características individuales dado que el ingreso depende de factores no observados (habilidad, calidad del empleador, informalidad, poder de negociación) que ninguna encuesta captura plenamente. El R^2 obtenido se ubica por tanto dentro de un rango esperado para este tipo de especificación. No obstante cerca del 59 % de la variabilidad permanece sin explicar. El análisis descriptivo (Tabla 7, Figura 6) ya había identificado diferencias sustanciales entre ramas de actividad económica (brecha de 0.98 puntos log entre sectores) variable no incluida en este modelo reducido. Es esperable que la incorporación de la variable categórica rama en el modelo completo (X_6) incremente el R^2 y capture parte de esta heterogeneidad sectorial. Con $n=100$, el R^2 ajustado (0.3793) constituye la medida más apropiada para evaluar el ajuste al penalizar los cinco grados de libertad consumidos por las covariables. La reducción de 0.4106 a 0.3793 es moderada, lo que sugiere que el modelo no está sobreajustado en relación con el número de predictores incluidos. Finalmente, la falta de significancia de edad y edad² plantea

una consideración relevante para la etapa de selección de modelo: su permanencia podría justificarse teóricamente por la especificación Mincer estándar aunque su bajo poder explicativo en este ajuste podría estar asociado a la correlación moderada con antigüedad ($r=0.381$) lo que introduciría cierto grado de redundancia entre ambas variables.

9. 2. Selección de modelos (covariables continuas)

9.1. a) Selección por R^2_{adj}

Tabla 10: Resumen de selección por R2 ajustado

Num_predictores	R2_ajustado
1	0.2316
2	0.3534
3	0.3909
4	0.3856
5	0.3793

Tabla 11: ANOVA - modelo por R2 ajustado

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
horas	1	10.9825	10.9825	19.9646	0.0000
escolaridad	1	21.7831	21.7831	39.5985	0.0000
antigüedad	1	3.8326	3.8326	6.9670	0.0097
Residuals	96	52.8096	0.5501	NA	NA

Tabla 12: Parámetros - modelo por R2 ajustado

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	11.2109	0.3384	33.1275	0.0000
horas	0.0289	0.0056	5.1428	0.0000
escolaridad	0.1077	0.0174	6.1941	0.0000
antigüedad	0.0022	0.0008	2.6395	0.0097

9.2. b) Selección por C_p de Mallows

Tabla 13: Resumen de selección por Cp de Mallows

Num_predictores	Cp
1	25.3124
2	7.0389

Num_predictores	Cp
3	2.2023
4	4.0361
5	6.0000

Tabla 14: ANOVA - modelo por Cp

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
horas	1	10.9825	10.9825	19.9646	0.0000
escolaridad	1	21.7831	21.7831	39.5985	0.0000
antigüedad	1	3.8326	3.8326	6.9670	0.0097
Residuals	96	52.8096	0.5501	NA	NA

Tabla 15: Parámetros - modelo por Cp

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	11.2109	0.3384	33.1275	0.0000
horas	0.0289	0.0056	5.1428	0.0000
escolaridad	0.1077	0.0174	6.1941	0.0000
antigüedad	0.0022	0.0008	2.6395	0.0097

9.3. c) Stepwise (ambas direcciones, AIC)

`ln_ingreso ~ horas + escolaridad + antigüedad`

Tabla 16: ANOVA - modelo Stepwise

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
horas	1	10.9825	10.9825	19.9646	0.0000
escolaridad	1	21.7831	21.7831	39.5985	0.0000
antigüedad	1	3.8326	3.8326	6.9670	0.0097
Residuals	96	52.8096	0.5501	NA	NA

Tabla 17: Parámetros - modelo Stepwise

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	11.2109	0.3384	33.1275	0.0000
horas	0.0289	0.0056	5.1428	0.0000
escolaridad	0.1077	0.0174	6.1941	0.0000
antigüedad	0.0022	0.0008	2.6395	0.0097

9.4. d) Selección hacia adelante (Forward)

`ln_ingreso ~ escolaridad + horas + antigüedad`

Tabla 18: ANOVA - modelo Forward

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
escolaridad	1	21.4004	21.4004	38.9027	0.0000
horas	1	11.3653	11.3653	20.6604	0.0000
antigüedad	1	3.8326	3.8326	6.9670	0.0097
Residuals	96	52.8096	0.5501	NA	NA

Tabla 19: Parámetros - modelo Forward

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	11.2109	0.3384	33.1275	0.0000
escolaridad	0.1077	0.0174	6.1941	0.0000
horas	0.0289	0.0056	5.1428	0.0000
antigüedad	0.0022	0.0008	2.6395	0.0097

9.5. e) Selección hacia atrás (Backward)

`ln_ingreso ~ horas + escolaridad + antigüedad`

Tabla 20: ANOVA - modelo Backward

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
horas	1	10.9825	10.9825	19.9646	0.0000
escolaridad	1	21.7831	21.7831	39.5985	0.0000
antigüedad	1	3.8326	3.8326	6.9670	0.0097
Residuals	96	52.8096	0.5501	NA	NA

Tabla 21: Parámetros - modelo Backward

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	11.2109	0.3384	33.1275	0.0000
horas	0.0289	0.0056	5.1428	0.0000
escolaridad	0.1077	0.0174	6.1941	0.0000
antigüedad	0.0022	0.0008	2.6395	0.0097

9.6. Conclusión sobre la selección de modelos

La aplicación conjunta de los cinco metodos de seleccion — R_{adj}^2 , C_p de Mallows, *stepwise*, seleccion hacia adelante y selección hacia atrás— sobre el conjunto de covariables continuas produjo un resultado inusualmente concluyente: los cinco métodos convergen exactamente en el mismo modelo final, compuesto por horas trabajadas, escolaridad y antigüedad en el empleo actual con exclusión sistemática de la edad y su término cuadrático. El criterio de R_{adj}^2 alcanzo su maximo (0.3909) precisamente en el modelo de tres predictores tras incrementarse desde 0.2316 (un predictor) y 0.3534 (dos predictores), y decrecer nuevamente al incorporar edad (0.3856) o edad y edad² (0.3793) de forma analoga el estadístico C_p tocó su minimo (2.20) en ese mismo modelo de tres variables —valor cercano a $p = 4$, lo que indica un sesgo estimado practicamente nulo respecto al modelo saturado— frente a valores de 25.31, 7.04, 4.04 y 6.00 para los modelos de una, dos, cuatro y cinco variables respectivamente. Las busquedas secuenciales por AIC (*stepwise*, *forward* y *backward*) reprodujeron la misma trayectoria y el mismo punto de convergencia, retirando primero edad² y luego edad en cada una de sus iteraciones.

El modelo resultante,

$$\widehat{\ln(Y_i)} = 11.21 + 0.0289 \text{ horas}_i + 0.1077 \text{ escolaridad}_i + 0.00222 \text{ antigüedad}_i,$$

es globalmente significativo ($F_{(3,96)} = 22.18$, $p < 0.001$) y explica el 40.93 % de la variabilidad del log-ingreso ($R_{adj}^2 = 0.3909$), una perdida marginal de apenas 1.13 puntos porcentuales de R^2 respecto al modelo completo de cinco covariables (41.06 %) lo que confirma que edad y edad² aportaban una fraccion de varianza practicamente despreciable. Los tres coeficientes retenidos son individualmente significativos al 5 % —horas ($\hat{\beta} = 0.0289$, $p < 0.001$), escolaridad ($\hat{\beta} = 0.1077$, $p < 0.001$) y antigüedad ($\hat{\beta} = 0.00222$, $p = 0.0097$)— de modo que ninguna variable sobrevive en el modelo por mero artificio del procedimiento de busqueda.

Este resultado obliga a matizar la Hipótesis 1 planteada en la Sección 6.1. La componente de escolaridad se confirma con solidez: su coeficiente conserva el signo positivo esperado por la teoría del capital humano y es el más significativo de los tres retenidos. sin embargo la componente de edad —tanto en su efecto lineal como en el cuadrático que debia capturar el perfil cóncavo de la ecuación de Mincer— no se sostiene: ya en el modelo completo sus coeficientes no eran significativos ($p = 0.795$ para edad y $p = 0.850$ para edad², Seccion “Estimación del modelo”), y los cinco metodos de selección coinciden en descartarla por completo. Esto no implica necesariamente que la relación edad-ingreso sea inexistente en la población de trabajadores colombianos —la curva LOESS de la Figura 3 sí insinuaba visualmente el ascenso y posterior descenso esperado— sino que, con una muestra de apenas $n = 100$ observaciones y una correlación de Pearson entre edad y log-ingreso practicamente nula ($r = -0.041$) el efecto no resulta estadísticamente detectable una vez controlado por escolaridad, horas trabajadas y antigüedad. La unanimidad de los cinco criterios de selección —que difieren en su lógica (ajuste penalizado, sesgo respecto al modelo completo, y búsqueda secuencial por verosimilitud) pero llegan al mismo resultado— constituye evidencia razonablemente robusta de que el modelo reducido de tres variables es con los datos disponibles, la especificación más parsimoniosa y defendible sin que ello descarte que una muestra de mayor tamaño pudiera revelar el efecto no lineal de la edad que la teoria anticipa.

10. 3. Diagnóstico de supuestos y elección final del modelo

Cargando paquete requerido: zoo

Adjuntando el paquete: 'zoo'

The following objects are masked from 'package:base':

as.Date, as.Date.numeric

Tabla 22: Verificación de supuestos: modelo completo vs. modelo seleccionado

Modelo	Shapiro W	p	BP	p	DW	p	AIC	BIC
W Completo (5 continuas)	0.9726	0.0348	12.2775	0.0312	1.9464	0.3940	233.72	251.96
W1 Reducido (horas+escolaridad+antigüedad)	0.9713	0.0278	9.6643	0.0216	1.9361	0.3731	229.94	242.97

Tabla 23: VIF - modelo completo (5 continuas)

Variable	VIF_completo
horas	1.128
escolaridad	1.094
edad	39.181
edad2	39.111
antigüedad	1.317

Tabla 24: VIF - modelo reducido

Variable	VIF_reducido
horas	1.109
escolaridad	1.001
antigüedad	1.110

Tabla 25: Prueba F parcial: ¿aportan conjuntamente edad y edad² sobre el modelo reducido?

Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
96	52.8096	NA	NA	NA	NA
94	52.6961	2	0.1134	0.1012	0.9039

11. 4. Coeficientes de regresión estandarizados

Tabla 26: Coeficientes de regresión estandarizados, ordenados por magnitud

	Variable	Beta_no_estandarizado	Beta_estandarizado	Beta_abs
escolaridad	escolaridad	0.10768	0.4862	0.4862
horas	horas	0.02892	0.4247	0.4247
antigüedad	antigüedad	0.00222	0.2181	0.2181

La escolaridad es la variable que más aporta a la explicación del logaritmo del ingreso laboral, con el coeficiente estandarizado de mayor magnitud en valor absoluto ($|\hat{\beta}_2^*| = 0.4862$). Le sigue muy de cerca horas trabajadas ($|\hat{\beta}_1^*| = 0.4247$), y en un distante tercer lugar antigüedad ($|\hat{\beta}_3^*| = 0.2181$), con un aporte relativo de menos de la mitad que el de escolaridad.

Esto es una conclusión distinta —y complementaria— a la que se obtiene mirando solo los coeficientes sin estandarizar: en la escala original, el coeficiente de escolaridad (0.108) parece casi 4 veces más grande que el de horas (0.029), lo cual podría hacer pensar erróneamente que escolaridad domina con mucha más holgura. Pero esa comparación es engañosa porque las tres variables están en unidades completamente distintas (años, horas semanales, meses), y una variable con mayor rango de variación natural (como horas, que va de 3 a 76) puede producir un coeficiente pequeño en su escala original y aun así tener un efecto comparable sobre la respuesta. Al estandarizar —expresando el efecto de cada covariable en términos de cuántas desviaciones estándar cambia $\ln(Y)$ por cada desviación estándar de cambio en X_j — se obtiene una métrica comparable entre variables, y bajo esa métrica escolaridad y horas trabajadas resultan tener un aporte muy similar (0.486 vs. 0.425), mientras que antigüedad, pese a ser estadísticamente significativa ($p = 0.0097$ en el modelo original), es la que menos contribuye de las tres en términos de magnitud del efecto.

Esto es coherente con la teoría del capital humano y con la literatura citada en la introducción [5]: la escolaridad ha sido consistentemente el factor con mayor poder explicativo sobre los diferenciales de ingreso laboral en Colombia, y este resultado lo confirma también en términos de magnitud relativa del efecto, no solo de significancia estadística.

12. 5. Prueba de significancia individual de los parámetros

Tabla 27: Prueba t individual (gl=96, t_crítico= ± 1.985)

Parámetro	Estimación	Error Estándar	t calculado	p-valor	Decision
horas	0.02892	0.00562	5.143	0.000001	Rechaza H0
escolaridad	0.10768	0.01738	6.194	0.000000	Rechaza H0
antigüedad	0.00222	0.00084	2.640	0.009690	Rechaza H0

Para cada parámetro β_j ($j = 1, 2, 3$) del modelo $\ln(Y_i) = \beta_0 + \beta_1 \text{horas}_i + \beta_2 \text{escolaridad}_i + \beta_3 \text{antigüedad}_i + \varepsilon_i$, se plantea:

$$H_0 : \beta_j = 0 \quad \text{vs.} \quad H_1 : \beta_j \neq 0$$

El estadístico de prueba es:

$$t_{calc} = \frac{\hat{\beta}_j - 0}{\text{ee}(\hat{\beta}_j)} \sim t_{(n-p-1)} \text{ bajo } H_0$$

con $n = 100$, $p = 3$ covariables, por lo que los grados de libertad son $n - p - 1 = 96$.

Criterio de decisión (nivel de significancia $\alpha = 0.05$): se rechaza H_0 si $|t_{calc}| > t_{0.025, 96} = 1.9850$, o equivalentemente si el p-valor asociado es menor que $\alpha = 0.05$.

En los tres casos $|t_{calc}| > t_{0.025, 96} = 1.985$ (5.143, 6.194 y 2.640, todos superan el umbral), y los tres p-valores son menores que $\alpha = 0.05$. Por lo tanto, se rechaza H_0 para β_1 , β_2 y β_3 : existe evidencia estadística suficiente, al 5 % de significancia, para afirmar que horas trabajadas, escolaridad y antigüedad tienen individualmente un efecto significativo distinto de cero sobre el logaritmo del ingreso laboral mensual, una vez controlado por las demás variables del modelo. Cabe destacar que β_3 (antigüedad) es la que presenta el margen más estrecho de rechazo—su p-valor (0.0097) es el único que estaría cerca de no rechazarse a un nivel de significancia más estricto, como $\alpha = 0.01$ ($t_{0.005, 96} = 2.628$; en ese caso, $2.640 > 2.628$, por lo que aún así se rechazaría H_0 , aunque por un margen mínimo)—, mientras que horas y escolaridad son significativas incluso a niveles de significancia mucho más exigentes.

13. 6. Prueba de suma de cuadrados extra (test lineal general)

Aunque el análisis de la Sección 8.3 y la selección de modelos de la Sección 9 mostraron que edad y edad^2 no son significativas de forma individual, la significancia individual (prueba t) no equivale a significancia conjunta. Dado que ambas covariables representan en conjunto la componente cuadrática del perfil edad-ingreso propuesto por la teoría del capital humano (Mincer, 1974), la forma correcta de evaluarlas es probando su aporte **conjunto** mediante una prueba de suma de cuadrados extra (test lineal general), comparando el modelo reducido contra el modelo completo.

Modelo completo (Ω):

$$\ln(Y_i) = \beta_0 + \beta_1 \text{horas}_i + \beta_2 \text{escolaridad}_i + \beta_3 \text{edad}_i + \beta_4 \text{edad}_i^2 + \beta_5 \text{antigüedad}_i + \varepsilon_i$$

Modelo reducido (ω):

$$\ln(Y_i) = \beta_0 + \beta_1 \text{horas}_i + \beta_2 \text{escolaridad}_i + \beta_3 \text{antigüedad}_i + \varepsilon_i$$

Hipótesis:

$$H_0 : \beta_{\text{edad}} = \beta_{\text{edad}^2} = 0 \quad \text{vs.} \quad H_1 : \text{al menos uno de } \beta_{\text{edad}}, \beta_{\text{edad}^2} \neq 0$$

Estadístico de prueba:

$$F = \frac{[SSE(\omega) - SSE(\Omega)] / (gl_{\omega} - gl_{\Omega})}{SSE(\Omega) / gl_{\Omega}}$$

Con $SSE(\omega) = 52.8096$ ($gl_{\omega} = 96$) y $SSE(\Omega) = 52.6961$ ($gl_{\Omega} = 94$):


$$F = \frac{(52.8096 - 52.6961)/2}{52.6961/94} = \frac{0.0567}{0.5606} = 0.1012$$

Distribución bajo H_0 : $F \sim F_{(2, 94)}$

Valor P: $P(F_{(2, 94)} > 0.1012) = 0.9039$

Decisión: Dado que $p = 0.9039 \gg \alpha = 0.05$, no se rechaza H_0 .

Conclusión: No hay evidencia estadística suficiente con esta muestra de $n = 100$, para afirmar que edad y edad² contribuyen conjuntamente a explicar el logaritmo del ingreso laboral una vez que horas, escolaridad y antigüedad ya están en el modelo. Este resultado es consistente con la correlación de Pearson prácticamente nula entre edad y log-ingreso ($r = -0.041$) observada en el análisis descriptivo y respalda formalmente la elección del modelo reducido de tres variables como la especificación más parsimoniosa, sin que ello implique que el efecto edad-ingreso sea inexistente en la población (podría no ser detectable con este tamaño muestral).



14. 7. Observaciones atípicas, de balanceo e influyentes

Tabla 28: Observaciones marcadas como atípicas, de balanceo y/o influyentes

obs	residual_estudentizado	leverage	cook_d	dffits
3	2.227	0.036	0.0450	0.433
25	1.743	0.071	0.0573	0.484
31	-3.829	0.129	0.4764	-1.475
43	0.593	0.179	0.0192	0.276
46	0.108	0.103	0.0003	0.037
47	1.655	0.128	0.0985	0.633
52	-2.889	0.048	0.0976	-0.648
53	1.398	0.081	0.0428	0.416
54	-0.573	0.101	0.0092	-0.192
56	-0.589	0.083	0.0079	-0.177
60	0.095	0.114	0.0003	0.034
65	-0.582	0.141	0.0140	-0.236
67	0.304	0.090	0.0023	0.095
74	2.603	0.052	0.0881	0.611
87	0.188	0.135	0.0014	0.074
90	0.068	0.213	0.0003	0.035
100	-2.859	0.065	0.1314	-0.752

El diagnostico sobre el modelo final identifico 17 observaciones señaladas por al menos un criterio de detección. Cinco observaciones (filas 3, 31, 52, 74 y 100) presentaron residuales estudentizados fuera del rango $-2 < t < 2$, lo que indica un ingreso observado notablemente distinto al predicho por el modelo. Doce observaciones superaron el umbral de leverage ($2p/n=0.082p/n=0.08$), señalando combinaciones poco usuales de horas, escolaridad y antigüedad frente al resto de la muestra. Ocho observaciones superaron los umbrales de influencia global (distancia de Cook > 0.04 y/o DFFITS > 0.40). La observación 31 es la unica que aparece simultáneamente en las tres categorías, con una distancia de Cook (0.476) y un DFFITS (-1.48) sustancialmente más altos que los de cualquier otra observación de la muestra lo que la convierte en la candidata más fuerte a examinar como posible error de digitación.

14.1. Modelo sugerido

Se sugiere el modelo reducido $\ln(Y_i) = \beta_0 + \beta_1 \text{horas}_i + \beta_2 \text{escolaridad}_i + \beta_3 \text{antigüedad}_i + \varepsilon_i$ frente al modelo completo de cinco covariables continuas, por las siguientes razones:

1. **La prueba F parcial confirma que edad y edad² no aportan de forma conjunta** ($F_{(2,94)} = 0.101$, $p = 0.904$): no hay perdida real de capacidad explicativa al retirarlas (R^2 pasa de 0.4106 a 0.4093).
2. **Multicolinealidad severa en el modelo completo.** $VIF(\text{edad}) = 39.18$ y $VIF(\text{edad}^2) = 39.11$, muy por encima del umbral de alerta ($VIF > 10$), consecuencia de incluir edad y su cuadrado simultáneamente. Esto infla artificialmente los errores

estandar de ambas variables, explicando por qué resultaron no significativas pese al respaldo teórico de la ecuación de Mincer. El modelo reducido tiene VIF cercanos a 1 en las tres variables retenidas: no hay indicio de multicolinealidad.

3. **Menor AIC y BIC en el modelo reducido** (229.94 y 242.97, frente a 233.72 y 251.96 del modelo completo), pese a tener dos parámetros menos.
4. **Coherencia con la etapa de selección de modelos:** los cinco métodos de selección convergieron unánimemente en este modelo reducido.

Sin embargo, ambos modelos **rechazan la normalidad de los residuos** (Shapiro-Wilk, $p = 0.0348$ y $p = 0.0278$ respectivamente) y **rechazan la homocedasticidad** (Breusch-Pagan, $p = 0.0312$ y $p = 0.0217$) al 5 % de significancia, mientras que el supuesto de independencia se cumple sin problema en ambos (Durbin-Watson, $p \approx 0.38$). Esto indica que la elección entre estos dos modelos no resuelve por sí sola todos los problemas de especificación y que en una etapa posterior convendría explorar correcciones adicionales (errores estándar robustos, mínimos cuadrados ponderados, o revisión de observaciones influyentes) antes de dar el modelo por definitivo.

15. 8. Efecto de observaciones atípicas (sensibilidad del modelo)

Tabla 29: Parámetros ajustados sin observaciones atípicas ($n = 97$)

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	11.6658	0.2990	39.0224	0.0000
horas	0.0218	0.0051	4.2900	0.0000
escolaridad	0.0998	0.0153	6.5193	0.0000
antigüedad	0.0024	0.0007	3.1546	0.0022




Figura 7: Q-Q residuales estudentizados (sin observaciones atípicas)

¿Cambian notoriamente las estimaciones de los parámetros?

No de forma dramática, pero tampoco son idénticas. Los tres coeficientes conservan el signo esperado (positivo) y las tres variables siguen siendo significativas al 5 % — de hecho antigüedad mejora su significancia (p pasa de 0.0097 a 0.0022). El cambio mas notable es el de horas cuyo coeficiente cae de 0.0289 a 0.0218 (una reducción de aproximadamente 25 %): esto sugiere que al menos una de las observaciones eliminadas tenía una combinación atípica de horas trabajadas e ingreso que inflaba ligeramente esa pendiente. escolaridad cambia poco (~7 %).

¿Cambian los errores estándar?

Sí, de forma consistente: los errores estándar de los tres coeficientes disminuyen (horas: $0.0056 \rightarrow 0.0051$; escolaridad: $0.0174 \rightarrow 0.0153$; antigüedad: $0.0008 \rightarrow 0.0007$). Esto es coherente con lo esperado: al quitar observaciones que generaban residuales grandes se reduce la varianza residual del modelo y por tanto la precisión de las estimaciones mejora.

¿Cambia la significancia?

No se pierde ninguna significancia — al contrario, antigüedad la refuerza notablemente (su t pasa de 2.64 a 3.15). Ninguna variable que era significativa deja de serlo y ninguna que no lo era pasa a serlo (las tres ya eran significativas antes).

¿Mejóro la normalidad?

Sí. En el Q-Q plot de los residuales estudentizados del modelo sin atípicos prácticamente todos los puntos caen dentro de la banda de confianza de `qqPlot()`, con solo una leve desviación en el extremo superior derecho. Esto contrasta con el Q-Q del modelo original, donde las

observaciones 31, 52 y 100 se salían claramente de la banda en la cola inferior izquierda (residuales muy negativos). La mejora visual es consistente con que esas tres observaciones eran precisamente las responsables del rechazo de normalidad reportado en la Tabla 22 (Shapiro-Wilk, $p=0.0278$ en el modelo original con esas covariables). Conclusion general sobre el efecto de estas observaciones Las observaciones 31, 52 y 100 se comportaban como valores atípicos en la variable respuesta (residuales grandes) mas que como puntos de alto leverage que distorsionaran la relación estructural del modelo. Su eliminación no cambia la interpretación económica del modelo —los signos, el orden de magnitud y la significancia de horas, escolaridad y antigüedad se mantienen—, pero sí produce dos beneficios claros: (1) reduce los errores estándar y por tanto mejora la precisión de las estimaciones y (2) corrige el incumplimiento del supuesto de normalidad de los residuales que tenia el modelo original. Esto es consistente con la hipótesis de que se trataba de errores de digitación u observaciones genuinamente anomalas y no de casos representativos de la población que el modelo debiera seguir capturando.

La observación 47 aunque presenta el mayor leverage de la muestra (Figura del diagnóstico, panel Residuals vs Leverage), no se excluyó porque su distancia de Cook permanece muy por debajo del umbral de 0.5 indicando que su influencia sobre las estimaciones es limitada

16. 9. Diagnósticos de multicolinealidad

16.1. a) Matriz de correlación de las variables predictoras

Tabla 30: Matriz de correlación entre las variables predictoras del modelo reducido

	horas	escolaridad	antigüedad
horas	1.0000	0.0025	-0.3418
escolaridad	0.0025	1.0000	0.0922
antigüedad	-0.3418	0.0922	1.0000

16.2. b) Factores de Inflación de la Varianza (VIF)

Tabla 31: Factores de Inflación de la Varianza (VIF) - modelo reducido, sin observaciones atípicas

	Variable	VIF
horas	horas	1.1337
escolaridad	escolaridad	1.0099
antigüedad	antigüedad	1.1434

16.3. c) y d) Proporciones de varianza, índices y número de condición

Tabla 32: Proporciones de varianza e índices de condición (número de condición = 10.4081)

Dimen- sion	Autovalor	Indice_condi- cion	X.Intercept.	horas	escolaridad	antigüe- dad
Dim1	3.31947	1.0000	0.0099	0.0004	0.0011	0.1305
Dim2	0.54958	2.4576	0.0557	0.0086	0.0776	0.3490
Dim3	0.10031	5.7525	0.3152	0.0099	0.8694	0.3342
Dim4	0.03064	10.4081	0.6192	0.9811	0.0519	0.1863

17. 10. Intervalos de confianza y predicción

Tabla 33: Perfil de covariables usado (promedios muestrales)

horas	escolaridad	antigüedad
43.34021	11.25773	76.15464

Tabla 34: Intervalos al 90 % en escala log-ingreso (fila 1: respuesta media, fila 2: predicción)

	fit	lwr	upr
1	13.91266	13.80602	14.01930
1	13.91266	12.85696	14.96836

Tabla 35: Intervalos al 90 % en escala original de ingreso (\$)

	fit	lwr	upr
1	1102027	990554.7	1226044
1	1102027	383449.7	3167206

17.1. Interpretación

-Para un trabajador con el perfil promedio de la muestra sin observaciones atípicas (horas, escolaridad y antigüedad promedio, Tabla 33) el modelo predice un ingreso mensual esperado de \$1.102.027. -Intervalo de confianza al 90 % (\$990.554,7 – \$1.226.044): esto significa que estamos 90 % seguros de que el ingreso promedio de todos los trabajadores con ese perfil esta dentro de ese rango relativamente angosto. -Intervalo de predicción al 90 % (\$383.449,7 – \$3.167.206): este es mucho mas ancho porque no está prediciendo un promedio, sino el ingreso de una persona específica con ese perfil. Hay mucha más incertidumbre al predecir un individuo que un promedio, por eso el rango es tan amplio (casi \$2.8 millones de diferencia entre el límite inferior y superior).

18. 11. Respuesta a las hipótesis planteadas

18.1. Hipótesis 1: la escolaridad y la edad explican una parte sustancial de la variabilidad del ingreso laboral

Esta hipótesis se confirma solo parcialmente. El componente de **escolaridad** se sostiene con solidez en todas las especificaciones: en el modelo completo (**Tabla 8**) su coeficiente es $\hat{\beta} = 0.1093$ ($p < 0.0001$) y se mantiene prácticamente inalterado en el modelo reducido (**Tabla 20/21**, $\hat{\beta} = 0.1077$, $p < 0.0001$) y en el modelo sin observaciones atípicas (**Tabla 26**, $\hat{\beta} = 0.0998$, $p < 0.0001$). El signo positivo y la significancia son consistentes con la teoría del capital humano y con la asociación lineal moderada-fuerte observada descriptivamente ($r = 0.489$, **Figura 2**).

El componente de **edad** en cambio no se sostiene estadísticamente. En el modelo completo (**Tabla 8**) ni edad ($p = 0.7953$) ni edad² ($p = 0.8497$) resultan significativas y la prueba de suma de cuadrados extra realizada en la **Sección [Prueba de suma de cuadrados extra]** confirma que tampoco aportan de forma conjunta ($F_{(2,94)} = 0.1012$, $p = 0.9039$). Esto es coherente con la correlación de Pearson prácticamente nula entre edad y log-ingreso reportada en la **Figura 3** ($r = -0.041$), aunque la curva LOESS de esa misma figura sí insinuaba visualmente el perfil cóncavo esperado. Además la **Tabla 23** muestra que edad y edad² presentaban multicolinealidad severa entre sí ($VIF > 39$ en ambas) lo que también contribuye a explicar su falta de significancia individual en el modelo completo.

En conclusión la Hipótesis 1 se confirma únicamente en su componente de escolaridad; el componente de edad no encuentra respaldo estadístico con los datos de esta muestra ($n = 100$), lo cual no descarta que el efecto exista en la población, sino que sugiere que no es detectable con este tamaño muestral una vez controlado por las demás covariables.

18.2. Hipótesis 2: la rama de actividad económica genera diferencias sistemáticas en el ingreso, incluso después de considerar escolaridad y edad

Esta hipótesis encuentra respaldo **descriptivo** pero su confirmación **estadística formal queda pendiente**. La **Tabla 7** y la **Figura 6** muestran una brecha de 0.98 puntos en escala logarítmica entre el sector con mayor log-ingreso medio (Servicios sociales y otros, 14.19) y el de menor log-ingreso medio (Agropecuario, 13.21) una diferencia sustancial que es consistente con la heterogeneidad sectorial documentada en la literatura (Banco de la República, 2021).

Sin embargo el modelo estimado en las **Secciones 8 a 10** de este documento incluye únicamente las cinco covariables continuas; la variable **rama** (categórica) todavía no ha sido incorporada como conjunto de variables dummy al modelo de regresión. Por tanto, no es posible aún pronunciarse sobre si estas diferencias sectoriales se mantienen significativas **una vez controlado por escolaridad y edad** tal como exige la hipótesis. La evidencia descriptiva es sugestiva y apunta en la dirección esperada, pero su verificación formal (mediante los coeficientes de las dummies de rama y una prueba F sobre su significancia conjunta) queda como paso pendiente para la siguiente etapa del proyecto cuando se estime el modelo completo con la variable categórica incluida.

19. Conclusiones

El análisis descriptivo confirmó que la transformación logarítmica del ingreso laboral corrige de forma considerable la asimetría propia de esta variable (asimetría de -0.785 en el log-ingreso), lo que respalda su uso como variable de respuesta a lo largo de todo el ejercicio de modelación.

La estimación del modelo con las cinco covariables continuas (Tabla 8) resultó globalmente significativa ($F(5,94) = 13.10$, $p < 0.001$) y explico el 41.06 % de la variabilidad del log-ingreso, pero evidencio que edad y edad² no aportaban de forma individual ($p = 0.795$ y $p = 0.850$, respectivamente) — resultado que se explico posteriormente por la multicolinealidad severa entre ambas ($VIF > 39$, Tabla 23) consecuencia de incluir una variable y su termino cuadrático de forma simultanea. Los cinco metodos de selección de modelos empleados (R^2_{aj} , C_p de Mallows, stepwise, forward y backward, Sección 9) convergieron unánimemente en el mismo modelo de tres variables (horas, escolaridad y antigüedad) con una pérdida marginal de apenas 1.13 puntos porcentuales de R^2 frente al modelo completo (Tabla 10). La prueba de suma de cuadrados extra (Tabla 25) confirmó formalmente que edad y edad² no contribuyen de forma conjunta una vez controlado por las demás covariables ($F(2,94) = 0.101$, $p = 0.904$), respaldando estadísticamente la exclusión de ambas variables y resolviendo de paso el problema de multicolinealidad del modelo completo (VIF cercano a 1 en el modelo reducido, Tabla 24).

Sobre el modelo seleccionado, los coeficientes estandarizados (Tabla 26) mostraron que escolaridad ($| \beta | = 0.486$) y horas trabajadas ($| \beta | = 0.425$) aportan de forma muy similar a la explicación del log-ingreso, mientras que antigüedad aunque estadísticamente significativa (Tabla 27, $p = 0.0097$) es la que menos contribuye en magnitud ($| \beta | = 0.218$). Las tres variables resultaron individualmente significativas al 5 % mediante la prueba t (Tabla 27).

El diagnostico de observaciones atípicas, de balanceo e influyentes (Tabla 28) identificó la observación 31 como la más problemática con una distancia de Cook (0.476) y un DFFITS (-1.48) sustancialmente más altos que el resto de la muestra. Al eliminar las tres observaciones más atípicas (31, 52 y 100, Sección 8) se corrigió el incumplimiento del supuesto de normalidad de los residuales (mejora visible en el Q-Q plot, Figura 7) y se redujeron los errores estandar de los tres coeficientes sin alterar su significancia ni el signo esperado, lo que sugiere que estas observaciones se comportaban como errores de digitación o casos genuinamente anómalos mas que como puntos representativos de la población. Con esta muestra depurada ($n = 97$), los diagnosticos de multicolinealidad (Tabla 30-32) confirmaron la ausencia de problemas serios: VIF cercanos a 1 en las tres variables y un numero de condicion de 10.41 muy por debajo del umbral de alerta (30). Finalmente, para un trabajador con el perfil promedio de esta muestra depurada el modelo predice un ingreso mensual esperado de \$1.102.027 con un intervalo de confianza al 90 % relativamente angosto (\$990.555 – \$1.226.044) y un intervalo de predicción individual considerablemente mas amplio (\$383.450 – \$3.167.206) reflejando la incertidumbre inherente a predecir el ingreso de una persona particular frente al ingreso promedio de un grupo con las mismas características.

En conjunto, estos resultados matizan la Hipótesis 1: la escolaridad se confirma con solidez como el determinante de mayor peso relativo del ingreso laboral consistente con la teoría del capital humano, mientras que el componente de edad — pese a la intuición teórica y la curva LOESS descriptiva (Figura 3)— no logra sostenerse estadísticamente con esta muestra de $n = 100$, ni individual ni conjuntamente (Sección 13) lo cual no descarta el efecto en la población sino que sugiere que no es detectable con este tamaño muestral. La Hipótesis 2, sobre las brechas

de ingreso por rama de actividad económica, cuenta con respaldo descriptivo claro (brecha de 0.98 puntos log entre Servicios sociales y Agropecuario, Tabla 7) pero su confirmación estadística formal —incorporando la variable categorica como conjunto de variables dummy y probando su significancia conjunta mediante una prueba F— queda como tarea pendiente para la siguiente etapa del proyecto, en la que se estimará el modelo completo (continuas + rama).

Referencias

- [1] Mincer, J. (1974). *Schooling, Experience, and Earnings*. Columbia University Press.
- [2] Guataquí, J. C., García Suaza, A. & Rodríguez, M. (2009). *Estimaciones de los determinantes de los ingresos laborales en Colombia con consideraciones diferenciales para asalariados y cuenta propia*. Documentos de Trabajo No. 5756, Universidad del Rosario, Bogotá.
- [3] Banco de la República (2021). Desigualdades del ingreso en Colombia: ¿cuáles son sus determinantes y cómo se han afectado por la pandemia del Covid-19? *Ensayos sobre Política Económica*, No. 101.
- [4] Determinantes de los ingresos laborales de los economistas en Colombia: un análisis de modelación microeconómica (2019). *Panorama Económico*, Universidad de Cartagena.
- [5] Núñez, J. & Sánchez, F. (1998). *Educación y salarios relativos en Colombia*. Documentos de Trabajo, Departamento Nacional de Planeación.
- [6] Montgomery, D. C., Peck, E. A., & Vining, G. G. (2021). *Introduction to Linear Regression Analysis* (6th ed.). John Wiley & Sons.
- [7] Departamento Administrativo Nacional de Estadística – DANE. (2024). Gran Encuesta Integrada de Hogares (GEIH). Microdatos. Recuperado de <https://microdatos.dane.gov.co>