



Universidad Nacional de Colombia

Departamento de Estadística – Facultad de Ciencias

Análisis de Regresión – 3006918

**MODELADO DE LOS INGRESOS MENSUALES DE EMPLEADOS EN
COLOMBIA**

Aplicación de un Modelo de Regresión Lineal Múltiple

Docente: Isabel Cristina Ramírez Guevara

Yuliany Cifuentes Rondon
Daniela Cataño Hernández
Samir Alejandro Centeno Torrado

Medellín, Colombia – Semestre 2026-1

Índice

1	Enunciado del proyecto	3
2	Introducción	3
3	Contextualización del problema	3
4	Objetivo general	4
5	Relevancia del estudio	4
5.1	Variables seleccionadas	4
5.1.1	Descripción detallada de las variables	5
6	Modelo matemático propuesto	6
6.1	Hipótesis	6
7	Análisis descriptivo	7
7.1	Información sobre la base de datos	7
7.2	Selección de la muestra	7
7.3	Base consolidada	8
7.4	Variable respuesta: logaritmo del ingreso laboral mensual	8
7.5	Descripción de las covariables continuas	9
7.6	Descripción de la variable categórica	14
7.6.1	Rama de actividad económica	14
8	Estimación del modelo con covariables continuas	15
8.1	Ajuste del modelo	15
8.2	ANOVA del modelo	16
8.3	Interpretación rigurosa	17
9	Selección de modelos (covariables continuas)	18
9.1	a) Selección por R_{adj}^2	18
9.2	b) Selección por C_p de Mallows	18
9.3	c) Stepwise (ambas direcciones, AIC)	19
9.4	d) Selección hacia adelante (Forward)	20
9.5	e) Selección hacia atrás (Backward)	20
9.6	Conclusión sobre la selección de modelos	21
10	Diagnóstico de supuestos y elección final del modelo	22
10.1	Modelo sugerido	23
11	Conclusiones	24

1. Enunciado del proyecto

El proyecto consiste en buscar una base de datos con datos colombianos que contenga una variable de respuesta continua (), al menos cinco covariables continuas () y una variable categórica () con al menos tres categorías. Los análisis se realizan con máximo 100 registros. El proyecto tiene tres entregas y una exposición final.

1. Contextualizar el fenómeno a modelar: explicar el significado de la variable de respuesta y las covariables, la relevancia del estudio y su objetivo. Establecer dos hipótesis que se desean probar con el modelo.
2. Realizar un análisis descriptivo exhaustivo y pertinente para el tipo de modelo que se va a aplicar.

2. Introducción

En el presente proyecto se desarrolla un modelo de regresión lineal múltiple para analizar los factores que influyen en el ingreso mensual de profesionales en Colombia. Se consideran variables relacionadas con características laborales, educativas y demográficas, con el propósito de identificar los determinantes más relevantes del salario y cuantificar su impacto sobre los ingresos.

3. Contextualización del problema

El ingreso laboral es una de las variables centrales para el estudio del bienestar económico y del funcionamiento del mercado de trabajo. Desde la teoría del capital humano, propuesta originalmente por Mincer, se plantea que el salario de un individuo puede explicarse en buena medida por su nivel de escolaridad y por su experiencia laboral entendida esta última como una proxy del entrenamiento adquirido en el puesto de trabajo [1]. Este marco teórico dio origen a la conocida *ecuación de Mincer*, que modela el logaritmo del ingreso como función lineal de la educación y de la experiencia (y su forma cuadrática) y que constituye hasta hoy el punto de partida estándar para el análisis empírico de los determinantes salariales.

En el caso colombiano, esta relación ha sido documentada de manera consistente. Núñez y Sánchez [2] utilizando información de encuestas de hogares del DANE encuentran que la escolaridad ha sido el factor con mayor poder explicativo sobre los diferenciales de ingreso laboral en el país, y que su efecto se ha mantenido estable a lo largo de distintos periodos. En la misma línea Guataquí et al. [3], con datos de la Gran Encuesta Integrada de Hogares (GEIH), muestran que además de la educación, variables como la posición ocupacional y la experiencia potencial explican una parte relevante de la heterogeneidad salarial observada, y advierten sobre la importancia de separar estos efectos entre asalariados y trabajadores por cuenta propia, dado que ambos grupos responden a estructuras de determinación de ingresos distintas.

Estudios más recientes del banco de la república [4] confirman que estos patrones persisten e incluso se intensifican en contextos de choques económicos: al modelar los determinantes del ingreso laboral para el periodo 2010-2019, encuentran que la brecha salarial asociada al sexo

del trabajador y a la posición ocupacional continua siendo estadísticamente significativa una vez controlado por nivel educativo. A nivel de subgrupos poblacionales específicos, Panorama Económico [5] aplica una ecuación minceriana a profesionales en economía y encuentra que un año adicional de formación escolar incrementa significativamente la probabilidad de percibir ingresos más altos, evidenciando que el efecto de la educación sobre el salario no es homogéneo entre grupos ocupacionales, sino que varía según el perfil profesional analizado.

En conjunto, esta literatura sugiere que un modelo del ingreso laboral en Colombia debe incorporar, como mínimo, variables asociadas a la educación, la experiencia o antigüedad laboral y la heterogeneidad sectorial del mercado de trabajo, dado que son los determinantes que de manera recurrente resultan significativos en los estudios previos. El presente proyecto retoma este marco para proponer un modelo de regresión lineal múltiple sobre una muestra de trabajadores colombianos, incorporando la escolaridad, la edad (y su término cuadrático), la antigüedad en el empleo actual y la intensidad de trabajo (horas semanales) como covariables continuas, y la rama de actividad económica como variable categórica, con el fin de evaluar el peso relativo de estos factores sobre el ingreso laboral.

4. Objetivo general

Desarrollar un modelo de regresión lineal múltiple que permita explicar el logaritmo del ingreso laboral mensual de los trabajadores en Colombia a partir de variables asociadas a la teoría del capital humano y a la literatura empírica sobre determinantes salariales en el país, específicamente las horas de trabajo semanales, la escolaridad, la edad, la antigüedad en el empleo actual y la rama de actividad económica en la que se desempeña el trabajador.

5. Relevancia del estudio

La identificación de los factores que determinan los ingresos laborales es un tema central en la economía laboral y ha sido ampliamente estudiado en Colombia desde la perspectiva del capital humano [1, 2]. Sin embargo, buena parte de esta literatura se ha concentrado en variables de escolaridad y experiencia, dejando en un segundo plano el análisis conjunto con variables como la intensidad y continuidad laboral (horas trabajadas y antigüedad en el empleo actual). Este proyecto busca aportar evidencia adicional sobre el peso relativo de estos factores frente a los determinantes tradicionales, replicando además la evidencia existente sobre las diferencias de ingreso asociadas a la rama de actividad económica documentadas por el banco de la república [4]. Los resultados permitirán establecer que características tienen una influencia significativa sobre los salarios en la muestra analizada y contrastar estos hallazgos con lo reportado en la literatura previa.

5.1. Variables seleccionadas

Tabla 1: Variables seleccionadas, rol en el modelo y significado en el estudio.

Nombre	Código	Rol	Tipo	Significado
Logaritmo del ingreso laboral mensual	INGLABO (transformada)	Y	Continua	Ingreso laboral mensual transformado a escala logarítmica para reducir la asimetría de la distribución.
Horas trabajadas por semana	P6800	X1	Continua	Intensidad del trabajo desarrollado durante la semana de referencia.
Años de escolaridad	P3042 (recodificada)	X2	Continua	Años de educación formal aprobados, recodificados a partir del nivel educativo alcanzado; mide la acumulación de capital humano.
Edad	P6040	X3	Continua	Edad de la persona en años cumplidos; aproxima el ciclo de vida laboral.
Edad al cuadrado	Derivada de X3	X4	Continua	Captura el efecto no lineal (rendimientos decrecientes) de la edad sobre el ingreso.
Antigüedad en el empleo actual	P6426	X5	Continua	Meses en el empleo u ocupación actual; aproxima estabilidad y experiencia específica.
Rama de actividad económica	RAMA2D_R4	X6 (Z)	Categorica	Sector económico (CIU, 2 dígitos) en el que se desempeña el trabajador.

5.1.1. Descripción detallada de las variables

Y: Logaritmo del ingreso laboral mensual. La variable de respuesta corresponde al ingreso laboral mensual percibido por las personas ocupadas incluidas en la GEIH, expresado en pesos colombianos. Dado que en economía laboral es ampliamente reconocido que la distribución de los ingresos presenta una marcada asimetría positiva, la variable dependiente se transforma mediante el logaritmo natural, lo que reduce la asimetría, disminuye la influencia de valores extremos y permite interpretar los coeficientes del modelo como variaciones porcentuales aproximadas del ingreso (especificación clásica de Mincer, 1974).

X1: Horas trabajadas por semana. Número de horas que la persona trabajó habitualmente durante la semana de referencia en su ocupación principal. Se espera una relación positiva con el ingreso.

X2: Años de escolaridad. Construida a partir del nivel educativo alcanzado (P3042), recodificando cada uno de los 13 niveles a un número típico de años acumulados de educación formal. Para los niveles hasta la educación media, los años corresponden a la duración legal establecida por la Ley 115 de 1994 (primaria: 5 años; básica secundaria: 4 años adicionales; media: 2 años adicionales). Para los niveles de educación superior (técnica, tecnológica, universitaria y posgrados), se asume la duración típica de cada programa, siguiendo la convención de conversión utilizada en estudios de determinantes salariales con la GEIH (Núñez & Sánchez, 1998), dado que la encuesta no permite distinguir la duración exacta cursada por cada persona dentro de ese nivel.

X3: Edad. Edad de la persona en años cumplidos al momento de la encuesta. Se utiliza como proxy del ciclo de vida laboral en lugar de la experiencia potencial (Edad - Escolaridad - 6), evitando así que esta covariable dependa de la variable de escolaridad ya construida, y reduciendo el número de transformaciones y supuestos encadenados sobre la base de datos.

X4: Edad al cuadrado. Incorpora la relación cóncava entre edad e ingreso: los ingresos aumentan con la edad, pero a una tasa decreciente, consistente con el perfil edad-ingreso documentado en la literatura de capital humano.

X5: Antigüedad en el empleo actual. Meses que el trabajador lleva en su empleo u ocupación actual; aproxima estabilidad laboral y experiencia específica en la organización.

X6 (Z): Rama de actividad económica. Sector económico en el que se desempeña el trabajador, agrupado según la Clasificación Industrial Internacional Uniforme (CIIU) a 2 dígitos.

6. Modelo matemático propuesto

Con fundamento en la teoría del capital humano y en la especificación clásica de la ecuación de ingresos de Mincer, se propone estimar un modelo de regresión lineal múltiple en el que el logaritmo natural del ingreso laboral mensual constituye la variable dependiente:

$$\ln(Y_i) = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 X_{3i} + \beta_4 X_{4i} + \beta_5 X_{5i} + \beta_6 X_{6i} + \varepsilon_i$$

donde X_1 : horas trabajadas por semana; X_2 : años de escolaridad; X_3 : edad; X_4 : edad al cuadrado; X_5 : antigüedad en el empleo actual; X_6 : rama de actividad económica (dummy); β_0 : intercepto; ε_i : error aleatorio.

Antes de estimar el modelo definitivo se verificará el cumplimiento de los supuestos de la regresión lineal múltiple, evaluando la existencia de multicolinealidad mediante el Factor de Inflación de la Varianza (VIF), la homocedasticidad de los residuos, la normalidad de los errores y la posible presencia de observaciones influyentes.

6.1. Hipótesis

Las siguientes hipótesis se desprenden directamente de la contextualización presentada en la Introducción y la Relevancia (teoría del capital humano de Mincer, 1974, y la heterogeneidad del mercado laboral colombiano). Cada una se plantea de forma que pueda traducirse, en la etapa de modelación, en el signo y la significancia esperados de parámetros específicos del modelo $\ln(Y_i) = \beta_0 + \beta_1 X_{1i} + \dots + \beta_6 X_{6i} + \varepsilon_i$.

Hipótesis 1: la escolaridad y la edad explican una parte sustancial de la variabilidad del ingreso laboral. De acuerdo con la teoría del capital humano, se espera que los trabajadores con mayor escolaridad perciban ingresos más altos, y que el ingreso siga un perfil cóncavo respecto a la edad —creciente en las primeras etapas de la vida laboral, hasta el punto en que los rendimientos empiezan a decrecer—. En términos del modelo, esta hipótesis se traduce en $\beta_2 > 0$ (escolaridad), $\beta_3 > 0$ (edad) y $\beta_4 < 0$ (edad al cuadrado), reflejando el perfil cóncavo típico de la ecuación de Mincer; se espera además que ambos coeficientes sean estadísticamente significativos.

Hipótesis 2: la rama de actividad económica genera diferencias sistemáticas en el ingreso, incluso después de considerar la escolaridad y la edad. Dada la heterogeneidad e informalidad del mercado laboral colombiano descrita en la Relevancia, se espera que

existan brechas de ingreso entre sectores económicos que la educación y la edad por sí solas no logran explicar. En el modelo, esto se traduce en que al menos algunos de los coeficientes asociados a las variables dummy de rama de actividad (β_6) sean estadísticamente significativos y distintos de cero.

7. Análisis descriptivo

7.1. Información sobre la base de datos

La base de datos utilizada corresponde a la Gran Encuesta Integrada de Hogares (GEIH), operativo de enero de 2024, publicada por el Departamento Administrativo Nacional de Estadística (DANE). Los microdatos se descargaron en formato .zip desde el archivo nacional de microdatos del DANE (operativo de enero), disponible en el catálogo público: <https://microdatos.dane.gov.co/index.php/catalog/819/data-dictionary>. Se utilizan dos de sus módulos:

- **Ocupados:** contiene las variables laborales de las personas ocupadas (ingreso, horas trabajadas, antigüedad, rama de actividad, entre otras).
- **Características generales, seguridad social en salud y educación:** contiene las variables demográficas y educativas (edad, nivel educativo, grado aprobado).

Ambos módulos se identifican a nivel de persona mediante las llaves `directorio`, `secuencia_p` y `orden`, por lo que se unen (`left_join`) usando esa combinación.

Tras la unión, la construcción de variables y la eliminación de registros incompletos o inconsistentes (horas fuera de rango, escolaridad fuera de rango, etc.), la base analítica de referencia queda con 27128 observaciones.

La variable rama de actividad económica se construyó originalmente a partir de la clasificación CIIU a 2 dígitos (`rama2d_r4`), la cual presenta 36 categorías distintas en la muestra de 100 observaciones, 18 de ellas representadas por un único individuo. Dado que esta granularidad hace inviable estimar coeficientes confiables para cada categoría, se recodificó la variable en cinco sectores agregados —Agropecuaria; Industria, minería y construcción; Comercio, transporte y alojamiento; Servicios financieros y profesionales; y Servicios sociales, comunales y otros— siguiendo la agrupación estándar de secciones de la Clasificación Industrial Internacional Uniforme (CIIU Rev. 4, adaptada por el DANE). Esta recodificación conserva la interpretación económica de la variable como proxy de heterogeneidad sectorial, a la vez que garantiza un tamaño muestral mínimo razonable por categoría (entre 11 y 33 observaciones) para la etapa de estimación del modelo.

7.2. Selección de la muestra

Siguiendo la restricción del enunciado (máximo 100 registros), se aplicó un muestreo aleatorio simple (MAS) sobre la base analítica de referencia para obtener una muestra de $n = 100$ observaciones, fijando la semilla aleatoria en 123 para garantizar la reproducibilidad del muestreo. Bajo este esquema, cada individuo tuvo la misma probabilidad de selección:

$$\pi_i = \frac{n}{N} = \frac{100}{27128}$$

Tabla 2: Parámetros del muestreo aleatorio simple

Parametro	Valor
Población de referencia (N)	27128
Tamaño de muestra (n)	100
Fracción de muestreo (n/N)	0.37 %
Semilla aleatoria	123

7.3. Base consolidada

La base analítica final contiene 100 observaciones y 7 variables: la variable respuesta, cinco covariables continuas (horas, escolaridad, edad, edad al cuadrado y antigüedad) y una variable categórica (rama de actividad económica).

Tabla 3: Primeras diez observaciones de la base consolidada

ln_ingre- so	horas	escolaridad	edad	edad2	antigüe- dad	rama
13.12	48	16	26	676	12	Industria_mineria_construc- cion
12.77	20	5	38	1444	120	Servicios_financ_profesiona- les
14.81	50	5	55	3025	11	Agropecuario
14.08	48	9	54	2916	2	Comercio_transporte_aloja- miento
14.85	40	16	34	1156	36	Servicios_sociales_otros
14.22	40	17	39	1521	168	Servicios_sociales_otros
14.65	36	17	39	1521	120	Servicios_sociales_otros
14.62	48	13	23	529	18	Comercio_transporte_aloja- miento
13.12	48	11	37	1369	120	Agropecuario
14.51	30	11	36	1296	120	Comercio_transporte_aloja- miento


7.4. Variable respuesta: logaritmo del ingreso laboral mensual

Tabla 4: Estadísticos descriptivos del logaritmo del ingreso laboral mensual

Medida	Valor
n	100

Medida	Valor
Media	13.826
Mediana	13.964
Desviación estándar	0.95
Coefficiente de variación	6.9 %
Mínimo	10.597
Primer cuartil (Q1)	13.305
Tercer cuartil (Q3)	14.287
Máximo	15.83
Asimetría	-0.785

La Tabla anterior presenta los estadísticos descriptivos de la variable de respuesta ya transformada. En promedio, el log-ingreso de la muestra es de 13.826, con una mediana de 13.964; la cercanía entre ambas medidas y una asimetría de -0.785 son consistentes con el efecto esperado de la transformación logarítmica: corrige buena parte del sesgo positivo propio de la distribución original de los ingresos.



Se muestra el ingreso en su escala original y ya transformado a logaritmo: el histograma de la izquierda evidencia la asimetría positiva característica de los ingresos laborales (unos pocos valores muy altos alargan la cola derecha), mientras que el de la derecha muestra una distribución considerablemente más simétrica, lo que respalda el uso de $\ln(Y)$ como variable de respuesta del modelo.

7.5. Descripción de las covariables continuas

Tabla 5: Estadísticos descriptivos de las covariables continuas ($n = 100$)

Variable	Media	Mediana	DE	Min	Max	Q1	Q3
antigüedad	78.19	36.0	93.26	0	480	12	120
edad	41.38	39.0	12.81	19	71	32	50

Variable	Media	Mediana	DE	Min	Max	Q1	Q3
edad2	1874.86	1521.0	1144.50	361	5041	1024	2500
escolaridad	11.18	11.0	4.29	0	18	9	14
horas	42.78	47.5	13.96	3	76	40	48

La Tabla 5 muestra asimetrías marcadas entre las covariables continuas. La antigüedad es la más sesgada: su media (78.19 meses) casi duplica su mediana (36 meses), y su desviación estándar (93.26) supera a la propia media, lo que indica una fuerte cola derecha — la mayoría de los trabajadores lleva poco tiempo en su empleo actual (Q1 = 12 meses, Q3 = 120 meses), pero un grupo reducido con antigüedades de hasta 480 meses (40 años) arrastra el promedio hacia arriba. La edad, en cambio, presenta media y mediana cercanas (41.38 y 39 años) y una dispersión moderada (DE = 12.81), consistente con una distribución razonablemente simétrica en el rango de vida laboral activa (19-71 años). La escolaridad también es prácticamente simétrica (media 11.18, mediana 11 años), con la mitad central de la muestra (Q1-Q3) situada entre 9 y 14 años, es decir, entre bachillerato incompleto y estudios técnicos o tecnológicos. Las horas trabajadas muestran una mediana (47.5) superior a la media (42.78), lo que sugiere una cola hacia valores bajos: la mayoría trabaja entre 40 y 48 horas semanales (Q1-Q3), pero algunos casos de jornadas muy reducidas (mínimo de 3 horas) bajan el promedio general.




Figura 1: Log(Ingreso) vs. horas trabajadas por semana




Figura 2: Log(Ingreso) vs. años de escolaridad




Figura 3: Log(Ingreso) vs. edad




Figura 4: Log(Ingreso) vs. antigüedad en el empleo actual

Las Figuras Figura 1 a Figura 4 muestran la relación entre el log-ingreso y cada covariable continua, junto con una curva LOESS y el coeficiente de correlación de Pearson. La escolaridad presenta la asociación lineal más fuerte con el log-ingreso ($r=0.489$ $r = 0.489$ $r=0.489$), con una tendencia creciente y particularmente pronunciada en los niveles más altos de educación, consistente con los rendimientos crecientes a la educación superior documentados en la literatura. Las horas trabajadas muestran una asociación positiva moderada ($r=0.350$ $r = 0.350$ $r=0.350$), aunque la curva LOESS evidencia un aplanamiento a partir de las 40 horas semanales: superado ese umbral, trabajar más horas no se traduce en incrementos proporcionales del ingreso. La antigüedad exhibe una correlación lineal débil ($r=0.104$ $r = 0.104$ $r=0.104$), con la mayoría de las observaciones concentradas en valores bajos y un leve repunte solo en los casos de mayor antigüedad. La edad es el caso más particular: su correlación de Pearson es prácticamente nula ($r=-0.041$ $r = -0.041$ $r=-0.041$), pero la curva LOESS sí insinúa el perfil cóncavo esperado por la teoría del capital humano —un leve ascenso hasta la quinta década de vida seguido de un descenso—, lo que confirma que la relación no es de tipo lineal y respalda la inclusión del término cuadrático (edad^2) en el modelo en lugar de depender únicamente del coeficiente de correlación simple.

Se observa que los puntos de la Figura Figura 2 se agrupan en un número reducido de valores discretos (0, 5, 9, 11, 13, 14, 16, 17, 18 y 21 años) en lugar de distribuirse de forma continua. Esto es consecuencia directa del método de construcción de la variable: al no preguntarse en la GEIH el número exacto de años cursados sino el nivel educativo alcanzado, la escolaridad se aproxima mediante la duración típica asociada a cada nivel (Ley 115 de 1994 y convención de Núñez & Sánchez, 1998). Se trata, por tanto, de una variable discreta con una escala de intervalo bien definida, tratada como continua siguiendo la convención estándar en la literatura

de determinantes salariales, en la que “años de escolaridad” se modela habitualmente como covariable continua pese a su naturaleza discreta (Mincer, 1974; Núñez & Sánchez, 1998).

Tabla 6: Matriz de correlaciones de Pearson entre las variables continuas

	ln_ingreso	horas	escolaridad	edad	antigüedad
ln_ingreso	1.000	0.350	0.489	-0.041	0.104
horas	0.350	1.000	-0.012	-0.093	-0.313
escolaridad	0.489	-0.012	1.000	-0.233	0.038
edad	-0.041	-0.093	-0.233	1.000	0.381
antigüedad	0.104	-0.313	0.038	0.381	1.000




Figura 5: Matriz de correlaciones de Pearson entre las variables continuas (representación gráfica)

La Tabla 6 y la Figura 5 confirman la jerarquía observada en los diagramas de dispersión: la escolaridad (0.489) y las horas trabajadas (0.350) son las covariables más asociadas linealmente con el log-ingreso, seguidas de la antigüedad (0.104) y la edad (-0.041). En cuanto a la asociación entre covariables, la mayor correlación se presenta entre edad y antigüedad ($r=0.381$), lo cual es esperable dado que ambas están ligadas al ciclo de vida laboral; también destaca una correlación negativa moderada entre horas trabajadas y antigüedad ($r=-0.313$), y entre escolaridad y edad ($r=-0.233$), esta última consistente con la expansión histórica del acceso a la educación en Colombia, que ha elevado la escolaridad promedio de las cohortes más jóvenes frente a las de mayor edad. Ninguna de estas correlaciones supera el umbral de 0.5 usualmente considerado como señal de alerta temprana de multicolinealidad severa, aunque la asociación entre edad y antigüedad es la que ameritará mayor atención al calcular los VIF en la etapa de estimación del modelo.

7.6. Descripción de la variable categórica

7.6.1. Rama de actividad económica

Tabla 7: Distribución de la muestra y log-ingreso medio según sector económico agregado ($n = 100$)

rama	n	Media_ln_ingreso	Mediana_ln_ingreso
Comercio_transporte_alojamiento	33	13.78	13.96
Servicios_sociales_otros	24	14.19	14.11
Industria_mineria_construccion	20	13.94	14.02
Agropecuario	12	13.21	13.21
Servicios_financ_profesionales	11	13.61	13.96

La recodificación en cinco sectores agregados produjo una distribución mucho más manejable que la original: el grupo más grande, Comercio, transporte y alojamiento, concentra 33 observaciones, seguido de Servicios sociales y otros (24) e Industria, minería y construcción (20). Agropecuario reúne 12 observaciones y Servicios financieros y profesionales, el grupo más pequeño, queda con 11 — sensiblemente mejor que los 18 grupos con una sola observación que tenía la codificación original, aunque este último grupo sigue siendo el más vulnerable a la inestabilidad muestral y deberá vigilarse en la etapa de estimación (por ejemplo, revisando su apalancamiento e influencia sobre el modelo). En cuanto al log-ingreso medio, Servicios sociales y otros presenta el valor más alto (media 14.19, mediana 14.11), seguido de cerca por Industria, minería y construcción (13.94 y 14.02); en el otro extremo, Agropecuario registra el log-ingreso medio más bajo (13.21, mediana 13.21). Comercio, transporte y alojamiento —pese a ser el sector con más observaciones— y Servicios financieros y profesionales quedan en un nivel intermedio, con medias de 13.78 y 13.61 respectivamente, y medianas prácticamente iguales (13.96 en ambos casos).




Figura 6: Log(Ingreso) según sector económico agregado

La Figura 6 confirma la heterogeneidad sectorial sugerida por la Tabla 7 (nótese que el eje horizontal ordena los sectores alfabéticamente y no por tamaño muestral). Servicios sociales y otros presenta la mediana más alta y la caja más compacta de los cinco sectores —es decir, la menor dispersión en el 50 % central de sus datos—, aunque exhibe dos valores atípicos: uno muy alto, el mayor de toda la muestra, y otro bajo, que amplían su rango total pese a la estrechez de la caja. Industria, minería y construcción tiene la segunda mediana más alta y, a diferencia del sector anterior, no presenta valores atípicos, si bien sus bigotes cubren un rango amplio. Comercio, transporte y alojamiento y Servicios financieros y profesionales muestran medianas muy similares entre sí y ligeramente por debajo de Industria, consistentes con el empate observado en la Tabla 7 (13.96 en ambos casos); el primero registra dos valores atípicos bajos y el segundo uno solo, más extremo, que corresponde al valor mínimo de toda la muestra. Agropecuario registra la mediana más baja de los cinco sectores y la caja de mayor altura, lo que indica una mayor heterogeneidad interna en su 50 % central, sin valores atípicos marcados. En conjunto, la brecha entre el sector con mayor log-ingreso medio (Servicios sociales y otros, 14.19) y el de menor log-ingreso medio (Agropecuario, 13.21) es de 0.98 puntos en escala logarítmica, una diferencia sustancial que respalda la Hipótesis 2 sobre la existencia de brechas de ingreso asociadas al sector económico, aunque su significancia estadística formal deberá confirmarse en la etapa de estimación del modelo, controlando por escolaridad, edad, horas trabajadas y antigüedad.

8. Estimación del modelo con covariables continuas

8.1. Ajuste del modelo

Call:

```
lm(formula = ln_ingreso ~ horas + escolaridad + edad + edad2 +
    antigüedad, data = muestra)
```

Residuals:

```
      Min       1Q   Median       3Q      Max
-2.43540 -0.36965  0.03507  0.45412  1.90504
```

Coefficients:

```
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.097e+01  8.028e-01  13.659 < 2e-16 ***
horas        2.871e-02  5.728e-03   5.012 2.52e-06 ***
escolaridad  1.093e-01  1.834e-02   5.957 4.42e-08 ***
edad         9.561e-03  3.676e-02   0.260  0.7953
edad2       -7.814e-05  4.112e-04  -0.190  0.8497
antigüedad   2.064e-03  9.260e-04   2.228  0.0282 *
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.7487 on 94 degrees of freedom

Multiple R-squared: 0.4106, Adjusted R-squared: 0.3793

F-statistic: 13.1 on 5 and 94 DF, p-value: 1.122e-09

Tabla 8: Parámetros estimados del modelo con covariables continuas

Parámetro	Estimación	Error estándar	t	p-valor
(Intercept)	10.9656	0.8028	13.659	0.0000
horas	0.0287	0.0057	5.012	0.0000
escolaridad	0.1093	0.0183	5.957	0.0000
edad	0.0096	0.0368	0.260	0.7953
edad2	-0.0001	0.0004	-0.190	0.8497
antigüedad	0.0021	0.0009	2.228	0.0282

La ecuación ajustada es:

$$\widehat{\ln(Y_i)} = 10.97 + 0.0287 X_{1i} + 0.1093 X_{2i} + 0.0096 X_{3i} - 0.000078 X_{4i} + 0.00206 X_{5i}$$

donde X_1 : horas, X_2 : escolaridad, X_3 : edad, X_4 : edad², X_5 : antigüedad.

8.2. ANOVA del modelo

Tabla 9: Tabla ANOVA del modelo con covariables continuas

Fuente	Df	Sum Sq	Mean Sq	F value	Pr(>F)
horas	1	10.9825	10.9825	19.5908	0.0000
escolaridad	1	21.7831	21.7831	38.8570	0.0000
edad	1	1.0994	1.0994	1.9611	0.1647
edad2	1	0.0627	0.0627	0.1118	0.7388
antigüedad	1	2.7839	2.7839	4.9660	0.0282
Residuals	94	52.6961	0.5606	NA	NA

El estadístico F global es de 13.097 con 5 y 94 grados de libertad, con un p-valor de $1.12\text{e-}09$. El modelo explica el 41.06 % de la variabilidad total del log-ingreso ($R^2 = 0.4106$; R^2 ajustado = 0.3793).

8.3. Interpretación rigurosa

¿Es significativo el modelo? Sí, de forma inequívoca. La hipótesis nula del ANOVA global (todos los $\beta = 0$ excepto el intercepto) se rechaza con un p-valor prácticamente nulo. Al menos una covariable tiene poder explicativo real sobre el log-ingreso.

Pero “significativo globalmente” no es lo mismo que “todas las variables aportan”. Mirando los coeficientes individuales: horas, escolaridad y antigüedad son significativas al 5 % (antigüedad justo en el límite, $p = 0.028$); edad y edad² no lo son en absoluto ($p = 0.795$ y $p = 0.850$). Esto es coherente con lo que ya se había anticipado en el análisis descriptivo: la correlación de Pearson entre edad y log-ingreso era prácticamente nula ($r = -0.041$), y aunque la curva LOESS insinuaba un perfil cóncavo, aquí —controlando por las demás variables— ese efecto no resulta estadísticamente detectable con $n = 100$. Esto es un llamado de atención sobre la Hipótesis 1: la escolaridad sí se confirma ($\beta_2 > 0$, $p < 0.001$), pero el componente de edad de la hipótesis no se sostiene en este modelo reducido.

Sobre el 41.06 % de varianza explicada, es importante no sobre-interpretar ni subestimar:

- Para datos de corte transversal en economía laboral con encuestas de hogares, un R^2 de ~ 0.41 no es bajo — es habitual que ecuaciones de Mincer con variables individuales expliquen entre 20 % y 40 % de la varianza del log-salario, porque el ingreso individual depende de muchísimos factores no observados (habilidad, calidad del empleador, negociación, informalidad, etc.) que ninguna encuesta captura.
- Sin embargo, queda un 59 % sin explicar, y el propio análisis descriptivo del documento (Tabla 7, Figura 6) ya había detectado que la rama de actividad económica genera diferencias sustanciales (brecha de 0.98 puntos log entre sectores) que este modelo reducido no incorpora. Es razonable esperar que al añadir la variable categórica rama (el modelo completo con X_6) el R^2 aumente y que parte de la varianza residual se explique por heterogeneidad sectorial.
- Con $n = 100$, el R^2 ajustado (0.379) es la medida más honesta porque penaliza los 5 grados de libertad consumidos; la caída de 0.41 a 0.38 no es dramática, así que el modelo no está sobreajustado por el número de covariables.

- Dado que edad y edad² no aportan significancia, valdría la pena —en la etapa de selección de modelo— evaluar si conviene mantenerlas por justificación teórica (Mincer) pese a su no significancia, o si su falta de poder explicativo aquí se debe a la correlación moderada con antigüedad ($r = 0.381$) generando cierta redundancia entre esas dos variables.

9. Selección de modelos (covariables continuas)

Warning: package 'leaps' was built under R version 4.4.3

9.1. a) Selección por R^2_{adj}

Tabla 10: Resumen de selección por R2 ajustado

Num_predictores	R2_ajustado
1	0.2316
2	0.3534
3	0.3909
4	0.3856
5	0.3793

Tabla 11: ANOVA - modelo por R2 ajustado

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
horas	1	10.9825	10.9825	19.9646	0.0000
escolaridad	1	21.7831	21.7831	39.5985	0.0000
antigüedad	1	3.8326	3.8326	6.9670	0.0097
Residuals	96	52.8096	0.5501	NA	NA

Tabla 12: Parámetros - modelo por R2 ajustado

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	11.2109	0.3384	33.1275	0.0000
horas	0.0289	0.0056	5.1428	0.0000
escolaridad	0.1077	0.0174	6.1941	0.0000
antigüedad	0.0022	0.0008	2.6395	0.0097

9.2. b) Selección por C_p de Mallows

Tabla 13: Resumen de selección por Cp de Mallows

Num_predictores	Cp
1	25.3124
2	7.0389
3	2.2023
4	4.0361
5	6.0000

Tabla 14: ANOVA - modelo por Cp

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
horas	1	10.9825	10.9825	19.9646	0.0000
escolaridad	1	21.7831	21.7831	39.5985	0.0000
antigüedad	1	3.8326	3.8326	6.9670	0.0097
Residuals	96	52.8096	0.5501	NA	NA

Tabla 15: Parámetros - modelo por Cp

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	11.2109	0.3384	33.1275	0.0000
horas	0.0289	0.0056	5.1428	0.0000
escolaridad	0.1077	0.0174	6.1941	0.0000
antigüedad	0.0022	0.0008	2.6395	0.0097

9.3. c) Stepwise (ambas direcciones, AIC)

ln_ingreso ~ horas + escolaridad + antigüedad

Tabla 16: ANOVA - modelo Stepwise

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
horas	1	10.9825	10.9825	19.9646	0.0000
escolaridad	1	21.7831	21.7831	39.5985	0.0000
antigüedad	1	3.8326	3.8326	6.9670	0.0097
Residuals	96	52.8096	0.5501	NA	NA

Tabla 17: Parámetros - modelo Stepwise

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	11.2109	0.3384	33.1275	0.0000

	Estimate	Std. Error	t value	Pr(> t)
horas	0.0289	0.0056	5.1428	0.0000
escolaridad	0.1077	0.0174	6.1941	0.0000
antigüedad	0.0022	0.0008	2.6395	0.0097

9.4. d) Selección hacia adelante (Forward)

`ln_ingreso ~ escolaridad + horas + antigüedad`

Tabla 18: ANOVA - modelo Forward

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
escolaridad	1	21.4004	21.4004	38.9027	0.0000
horas	1	11.3653	11.3653	20.6604	0.0000
antigüedad	1	3.8326	3.8326	6.9670	0.0097
Residuals	96	52.8096	0.5501	NA	NA

Tabla 19: Parámetros - modelo Forward

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	11.2109	0.3384	33.1275	0.0000
escolaridad	0.1077	0.0174	6.1941	0.0000
horas	0.0289	0.0056	5.1428	0.0000
antigüedad	0.0022	0.0008	2.6395	0.0097

9.5. e) Selección hacia atrás (Backward)

`ln_ingreso ~ horas + escolaridad + antigüedad`

Tabla 20: ANOVA - modelo Backward

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
horas	1	10.9825	10.9825	19.9646	0.0000
escolaridad	1	21.7831	21.7831	39.5985	0.0000
antigüedad	1	3.8326	3.8326	6.9670	0.0097
Residuals	96	52.8096	0.5501	NA	NA

Tabla 21: Parámetros - modelo Backward

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	11.2109	0.3384	33.1275	0.0000
horas	0.0289	0.0056	5.1428	0.0000
escolaridad	0.1077	0.0174	6.1941	0.0000
antigüedad	0.0022	0.0008	2.6395	0.0097

9.6. Conclusión sobre la selección de modelos

La aplicación conjunta de los cinco métodos de selección — R_{adj}^2 , C_p de Mallows, *stepwise*, selección hacia adelante y selección hacia atrás— sobre el conjunto de covariables continuas produjo un resultado inusualmente concluyente: los cinco métodos convergen exactamente en el mismo modelo final, compuesto por horas trabajadas, escolaridad y antigüedad en el empleo actual, con exclusión sistemática de la edad y su término cuadrático. El criterio de R_{adj}^2 alcanzó su máximo (0.3909) precisamente en el modelo de tres predictores, tras incrementarse desde 0.2316 (un predictor) y 0.3534 (dos predictores), y decrecer nuevamente al incorporar edad (0.3856) o edad y edad² (0.3793); de forma análoga, el estadístico C_p tocó su mínimo (2.20) en ese mismo modelo de tres variables —valor cercano a $p = 4$, lo que indica un sesgo estimado prácticamente nulo respecto al modelo saturado—, frente a valores de 25.31, 7.04, 4.04 y 6.00 para los modelos de una, dos, cuatro y cinco variables, respectivamente. Las búsquedas secuenciales por AIC (*stepwise*, *forward* y *backward*) reprodujeron la misma trayectoria y el mismo punto de convergencia, retirando primero edad² y luego edad en cada una de sus iteraciones.

El modelo resultante,

$$\widehat{\ln(Y_i)} = 11.21 + 0.0289 \text{ horas}_i + 0.1077 \text{ escolaridad}_i + 0.00222 \text{ antigüedad}_i,$$

es globalmente significativo ($F_{(3,96)} = 22.18$, $p < 0.001$) y explica el 40.93 % de la variabilidad del log-ingreso ($R_{adj}^2 = 0.3909$), una pérdida marginal de apenas 1.13 puntos porcentuales de R^2 respecto al modelo completo de cinco covariables (41.06 %), lo que confirma que edad y edad² aportaban una fracción de varianza prácticamente despreciable. Los tres coeficientes retenidos son individualmente significativos al 5 % —horas ($\hat{\beta} = 0.0289$, $p < 0.001$), escolaridad ($\hat{\beta} = 0.1077$, $p < 0.001$) y antigüedad ($\hat{\beta} = 0.00222$, $p = 0.0097$)—, de modo que ninguna variable sobrevive en el modelo por mero artificio del procedimiento de búsqueda.

Este resultado obliga a matizar la Hipótesis 1 planteada en la Sección 6.1. La componente de escolaridad se confirma con solidez: su coeficiente conserva el signo positivo esperado por la teoría del capital humano y es el más significativo de los tres retenidos. Sin embargo, la componente de edad —tanto en su efecto lineal como en el cuadrático que debía capturar el perfil cóncavo de la ecuación de Mincer— no se sostiene: ya en el modelo completo sus coeficientes no eran significativos ($p = 0.795$ para edad y $p = 0.850$ para edad², Sección “Estimación del modelo”), y los cinco métodos de selección coinciden en descartarla por completo. Esto no implica necesariamente que la relación edad-ingreso sea inexistente en la población de trabajadores colombianos —la curva LOESS de la Figura 3 sí insinuaba visualmente el ascenso y posterior descenso esperado—, sino que, con una muestra de apenas $n = 100$ observaciones

y una correlación de Pearson entre edad y log-ingreso prácticamente nula ($r = -0.041$), el efecto no resulta estadísticamente detectable una vez controlado por escolaridad, horas trabajadas y antigüedad. La unanimidad de los cinco criterios de selección —que difieren en su lógica (ajuste penalizado, sesgo respecto al modelo completo, y búsqueda secuencial por verosimilitud) pero llegan al mismo resultado— constituye evidencia razonablemente robusta de que el modelo reducido de tres variables es, con los datos disponibles, la especificación más parsimoniosa y defendible, sin que ello descarte que una muestra de mayor tamaño pudiera revelar el efecto no lineal de la edad que la teoría anticipa.

10. Diagnóstico de supuestos y elección final del modelo

Warning: package 'lmtest' was built under R version 4.4.3

Cargando paquete requerido: zoo

Warning: package 'zoo' was built under R version 4.4.3

Adjuntando el paquete: 'zoo'

The following objects are masked from 'package:base':

as.Date, as.Date.numeric

Tabla 22: Verificación de supuestos: modelo completo vs. modelo seleccionado

Modelo	Shapiro-W	Shapiro-p	Breusch-Pagan_BP	Breusch-Pagan_p	Durbin-Watson_D	Durbin-Watson_p	AIC	BIC
W Completo (5 continuas)	0.9726	0.0348	12.2775	0.0312	1.9464	0.3940	233.72	251.96
W1 Reducido (horas+escolaridad+antigüedad)	0.9713	0.0278	9.6643	0.0216	1.9361	0.3731	229.94	242.97

Tabla 23: VIF - modelo completo (5 continuas)

Variable	VIF_completo
horas	1.128
escolaridad	1.094
edad	39.181
edad2	39.111
antigüedad	1.317


Variable	VIF_completo
----------	--------------

Tabla 24: VIF - modelo reducido

	Variable	VIF_reducido
horas	horas	1.109
escolaridad	escolaridad	1.001
antigüedad	antigüedad	1.110

Tabla 25: Prueba F parcial: ¿aportan conjuntamente edad y edad² sobre el modelo reducido?

Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
96	52.8096	NA	NA	NA	NA
94	52.6961	2	0.1134	0.1012	0.9039



10.1. Modelo sugerido

Se sugiere el modelo reducido $\ln(Y_i) = \beta_0 + \beta_1 \text{horas}_i + \beta_2 \text{escolaridad}_i + \beta_3 \text{antigüedad}_i + \varepsilon_i$ frente al modelo completo de cinco covariables continuas, por las siguientes razones:

1. **La prueba F parcial confirma que edad y edad² no aportan de forma conjunta** ($F_{(2,94)} = 0.101$, $p = 0.904$): no hay pérdida real de capacidad explicativa al retirarlas (R^2 pasa de 0.4106 a 0.4093).
2. **Multicolinealidad severa en el modelo completo.** $VIF(\text{edad}) = 39.18$ y $VIF(\text{edad}^2) = 39.11$, muy por encima del umbral de alerta ($VIF > 10$), consecuencia de incluir edad y su cuadrado simultáneamente. Esto infla artificialmente los errores estándar de ambas variables, explicando por qué resultaron no significativas pese al respaldo teórico de la ecuación de Mincer. El modelo reducido tiene VIF cercanos a 1 en las tres variables retenidas: no hay indicio de multicolinealidad.
3. **Menor AIC y BIC en el modelo reducido** (229.94 y 242.97, frente a 233.72 y 251.96 del modelo completo), pese a tener dos parámetros menos.
4. **Coherencia con la etapa de selección de modelos:** los cinco métodos de selección convergieron unánimemente en este modelo reducido.

Sin embargo, ambos modelos **rechazan la normalidad de los residuos** (Shapiro-Wilk, $p = 0.0348$ y $p = 0.0278$ respectivamente) y **rechazan la homocedasticidad** (Breusch-Pagan, $p = 0.0312$ y $p = 0.0217$) al 5 % de significancia, mientras que el supuesto de independencia se cumple sin problema en ambos (Durbin-Watson, $p \approx 0.38$). Esto indica que la elección entre estos dos modelos no resuelve por sí sola todos los problemas de especificación, y que en una etapa posterior convendría explorar correcciones adicionales (errores estándar robustos, mínimos cuadrados ponderados, o revisión de observaciones influyentes) antes de dar el modelo por definitivo.

11. Conclusiones

El análisis descriptivo confirma que la transformación logarítmica del ingreso laboral corrige de forma considerable la asimetría propia de esta variable (asimetría de -0.785 en el log-ingreso, frente a la marcada cola derecha visible en la escala original), lo que respalda su uso como variable de respuesta del modelo.

Entre las covariables continuas, la escolaridad es la que muestra la asociación lineal más fuerte con el log-ingreso ($r = 0.489$), seguida por las horas trabajadas ($r = 0.350$), aunque esta última se aplanan a partir de las 40 horas semanales, indicando rendimientos decrecientes de la intensidad laboral sobre el ingreso. La antigüedad presenta una correlación lineal débil ($r = 0.104$) y una distribución fuertemente asimétrica (media de 78.19 meses frente a una mediana de 36), mientras que la edad exhibe una correlación de Pearson prácticamente nula ($r = -0.041$), pese a que la curva LOESS insinúa el perfil cóncavo esperado por la teoría del capital humano —lo que confirma que su relación con el ingreso no es de tipo lineal y justifica la inclusión de su término cuadrático en el modelo en lugar de depender del coeficiente de correlación simple—. La matriz de correlaciones evidencia además que ninguna asociación entre covariables supera el umbral de 0.5 considerado como alerta temprana de multicolinealidad severa, si bien la relación entre edad y antigüedad ($r = 0.381$) —ambas ligadas al ciclo de vida laboral— es la más alta del conjunto y ameritará una revisión formal mediante el Factor de Inflación de la Varianza (VIF) en la etapa de estimación.

En cuanto a la rama de actividad económica, el análisis descriptivo detectó una limitación metodológica relevante en su codificación original (CIU a 2 dígitos): 36 categorías para apenas 100 observaciones, 18 de ellas representadas por una sola persona, lo cual habría producido coeficientes inestables y grados de libertad desperdiciados de haberse usado directamente en el modelo. Esta limitación se resolvió recodificando la variable en cinco sectores agregados (Agropecuaria; Industria, minería y construcción; Comercio, transporte y alojamiento; Servicios financieros y profesionales; y Servicios sociales, comunales y otros), con tamaños muestrales entre 11 y 33 observaciones por categoría. Una vez recodificada, la variable muestra diferencias claras en el nivel medio de ingreso entre sectores: Servicios sociales y otros e Industria, minería y construcción registran los log-ingresos medios más altos, mientras que Agropecuaria presenta el más bajo, con una brecha de 0.98 puntos en escala logarítmica entre ambos extremos.

En conjunto, estos resultados son coherentes con las dos hipótesis planteadas para el proyecto: la escolaridad y la edad muestran las asociaciones esperadas con el ingreso según la teoría del capital humano (Hipótesis 1), y la rama de actividad evidencia diferencias sistemáticas de ingreso entre sectores incluso antes de controlar por las demás covariables (Hipótesis 2). Sin embargo, ninguna covariable por sí sola explica la totalidad de la variabilidad del log-ingreso, lo que confirma la necesidad de evaluar sus efectos de forma conjunta en un modelo de regresión múltiple. Las siguientes etapas del proyecto deberán estimar dicho modelo y verificar formalmente sus supuestos —multicolinealidad (VIF), homocedasticidad, normalidad de los residuos y presencia de observaciones influyentes—, prestando particular atención a la relación entre edad y antigüedad, y al reducido tamaño muestral del sector Servicios financieros y profesionales dentro de la variable rama.

Referencias

- [1] Mincer, J. (1974). *Schooling, Experience, and Earnings*. Columbia University Press.
- [2] Núñez, J. & Sánchez, F. (1998). Educación y salarios relativos en Colombia, 1976-1995: Determinantes, evolución e implicaciones para la distribución del ingreso. *Archivos de Macroeconomía*, No. 74. Departamento Nacional de Planeación, Bogotá.
- [3] Guataquí, J. C., García, A. & Rodríguez, M. Estimaciones de los determinantes de los ingresos laborales en Colombia. Banco de la República.
- [4] Banco de la República (2021). Desigualdades del ingreso en Colombia: ¿cuáles son sus determinantes y cómo se han afectado por la pandemia del Covid-19? *Ensayos sobre Política Económica*, No. 101.
- [5] Determinantes de los ingresos laborales de los economistas en Colombia: un análisis de modelación microeconómica (2019). *Panorama Económico*, Universidad de Cartagena.